

Wykład 1: Wprowadzenie do uczenia maszynowego



dr inż. Bartosz Czech

Katedra Genetyki · Uniwersytet Przyrodniczy we Wrocławiu

bartosz.czech@upwr.edu.pl

Plan i cel

- 1 Wprowadzenie do uczenia maszynowego
- 2 Przygotowanie danych
- 3 Uczenie nienadzorowane
- 4 Uczenie nadzorowane
- 5 Ocena modelu
- 6 Modele złożone i wybór cech
- 7 Wiarygodność modelu
- 8 Zastosowania i podsumowanie

Zaliczenie

Kurs kończy się **projektem zespołowym** — pełną analizą wybranego zbioru danych, od danych surowych aż po wnioski.

Obecność

- dopuszczalne nieobecności: **do 20%** zajęć — przy 8 spotkaniach **najwyżej 1**
- przekroczenie limitu rozpatrywane zgodnie z regulaminem studiów
- usprawiedliwienie — niezwłocznie po ustaniu przyczyny

Konsultacje: poniedziałek 14:00–15:30, pokój 306 w Katedrze Genetyki
(proszę o wcześniejszy kontakt mailowy: bartosz.czech@upwr.edu.pl)

- **James i in.**, *An Introduction to Statistical Learning* (R / Python) — statistical learning, obciążenie–wariancja, podział danych (rozdz. 2)
<https://www.statlearning.com/>
- **Boehmke & Greenwell**, *Hands-On Machine Learning with R* — proces modelowania, przeuczenie, ocena (rozdz. 1–2)
<https://bradleyboehmke.github.io/HOML/>
- **Kuhn & Silge**, *Tidy Modeling with R* — podział danych, resampling
<https://www.tmwr.org/>
- **Wickham i in.**, *R for Data Science* — fundament pracy z danymi w R
<https://r4ds.hadley.nz/>
- **VanderPlas**, *Python Data Science Handbook* — NumPy, pandas, scikit-learn: fundament pracy z danymi w Pythonie
<https://jakevdp.github.io/PythonDataScienceHandbook/>
- **scikit-learn** — *User Guide* — kanoniczna referencja metod ML w Pythonie
https://scikit-learn.org/stable/user_guide.html

- 1 Uczenie maszynowe w analizie danych biologicznych
- 2 Rodzaje uczenia: nadzorowane i nienadzorowane
- 3 Język i dane: cechy, cel, macierz X i wektor y
- 4 Jak model się uczy — i dlaczego się myli
- 5 Proces analizy danych i zasada braku przecieku
- 6 Zbiór danych: mikrobiom w raku jelita grubego
- 7 Narzędzia i organizacja pracy

Jeden eksperyment sekwencjonowania — tysiące zmiennych na próbkę:

- transkryptom — ekspresja dziesiątek tysięcy genów
- metagenom — liczebności setek gatunków drobnoustrojów
- warianty genetyczne — miliony pozycji w genomie

Konsekwencja


Zmiennych często znacznie więcej niż próbek. Metody „jedna zmienna naraz” przestają wystarczać.

Definicja robocza

Uczenie maszynowe to budowanie modeli, które **uczą się wzorców z danych**, zamiast być zaprogramowane regułą wprost — i wykorzystują te wzorce do predykcji na nowych, niewidzianych danych.

Kluczowe słowa:

- **wzorzec** — zależność między cechami a wielkością przewidywaną
- **nowe dane** — model ma działać poza zbiorem, na którym się uczył



- **AI** — najszersze pojęcie: systemy realizujące zadania wymagające „inteligencji”
- **ML** — poddziedzina AI: reguły wyprowadzane z danych, nie programowane wprost
- **DL** — poddziedzina ML: sieci neuronowe o wielu warstwach



Statystyka klasyczna i uczenie maszynowe odpowiadają na odmienne pytania:

Wnioskowanie

Czy dany czynnik wywiera wpływ i jak jest on silny?

Predykcja

Czy na podstawie danych można przewidzieć wynik dla nowej próbki?

	Statystyka klasyczna	Uczenie maszynowe
Pytanie	Czy efekt istnieje?	Czy potrafię przewidzieć?
Oceniamy	istotność, wielkość efektu	skuteczność na nowych danych
Typowy błąd	mylenie korelacji z przyczyną	model, który tylko <i>pamięta</i> dane treningowe

Kurs skupia się na **prawej kolumnie**: budowa modeli i ocena na nowych danych.

Dobre przesłanki

- wiele cech, złożone zależności
- cel: trafna predykcja
- dostatecznie dużo przykładów

Ostrożnie

- bardzo mało próbek
- potrzebne wyjaśnienie przyczyny
- dane niskiej jakości

Zasada

Uczenie maszynowe nie zastępuje myślenia o danych — je wspomaga. Model jest tak dobry, jak dane i pytanie, które mu postawimy.

Metody tego kursu działają dziś w praktyce badawczej i klinicznej:

- **przewidywanie struktury białka** z sekwencji (AlphaFold)
- **klasyfikacja wariantów** na patogenne / łagodne
- **histopatologia** — wykrywanie zmian nowotworowych na preparatach
- **mikrobiom jako biomarker** — sygnatury składu w chorobach jelita
- **wiek biologiczny** z profilu metylacji DNA (zegary epigenetyczne)

Wspólny mianownik

Wiele cech naraz, złożone zależności, cel = trafna predykcja dla nowej próbki. Dokładnie ten schemat przejdziemy na danych mikrobiomowych.

Nie zastąpi

- dobrego pytania badawczego
- kontroli jakości danych
- wiedzy dziedzinowej o biologii

Nie udowodni

- przyczynowości (tylko zależność)
- mechanizmu biologicznego
- że sygnał nie jest artefaktem serii

Model znajdzie **jakiś** wzorec niemal zawsze — także w danych czysto losowych. Zadaniem analityka jest odróżnić wzorec rzeczywisty od przypadkowego.

Zbiór danych

Wykłady opieramy na jednym zbiorze danych i jednym zadaniu: na podstawie **mikrobiomu jelitowego** odróżnić osobę z **rakiem jelita grubego** (CRC, *colorectal cancer*) od osoby zdrowej.


- **Dane** — publiczna kohorta **ZellerG_2014** z pakietu **curatedMetagenomicData** (Bioconductor)
- **Cechy (X)** — względne liczebności setek taksonów z sekwencjonowania metagenomicznego próbki kału
- **Cel (y)** — grupa kliniczna: zdrowy / gruczolak / CRC

- jelito zasiedlają **setki gatunków** drobnoustrojów (mikrobiom); ich skład wiąże się ze zdrowiem gospodarza — metabolizmem, odpornością, stanem zapalnym — i **zmienia się** w wielu chorobach
- CRC to **jeden z najczęstszych nowotworów**; wczesne wykrycie znacząco poprawia rokowanie
- u pacjentów z CRC obserwuje się **powtarzalne zmiany** składu mikrobiomu — jest więc szansa, że sygnał w danych istnieje

Pytanie badawcze

Czy skład mikrobiomu niesie sygnał wystarczający, by odróżnić pacjentów z CRC od osób zdrowych?

Rodzaje uczenia



Jedno kryterium podziału: **czy dane mają etykiety.**

Rodzaje pośrednie uczenia

Oprócz uczenia nadzorowanego i nienadzorowanego spotykają Państwo warianty pośrednie:

Rodzaj	Na czym polega
półnadzorowane	część próbek z etykietą, większość bez — etykietowanie bywa kosztowne
samonadzorowane	etykiety tworzone automatycznie z samych danych (np. fragment sekwencji)
ze wzmocnieniem	agent uczy się decyzji przez nagrody — rzadkie w analizie danych <i>omics</i>

Na tym kursie

Skupiamy się na dwóch głównych: **nadzorowanym** (trzon kursu) i **nienadzorowanym** (eksploracja).
Pozostałe — dla orientacji.

Dysponujemy parami: cechy $\rightarrow$ znana odpowiedź. Model uczy się odwzorowania z cech na odpowiedź.

Przykłady biologiczne

- czy próbka pochodzi od chorego, czy zdrowego (klasyfikacja)
- jaki jest wiek biologiczny na podstawie metylacji (regresja)
- czy wariant jest patogenny (klasyfikacja)

	Klasyfikacja	Regresja
Cel	kategoria	liczba
Przykład	CRC / zdrowy	stężenie metabolitu
Wynik	etykieta lub prawdopodobieństwo	wartość ciągła
Miara	dokładność, ROC-AUC, F1	błąd średniokwadratowy

Różnica: **typ zmiennej celu** (a więc i sposób oceny). Nasz cel — kategoriyczny, więc **klasyfikacja**.

Klasyfikacja binarna i wieloklasowa

Liczba kategorii zmienia trudność problemu i dobór miar:

- **binarna** — dwie klasy (chory / zdrowy); najprostsza do oceny
- **wieloklasowa** — trzy lub więcej kategorii (np. stadia choroby)

Przykład z realnej kohorty CRC

Metadane dzielą próbki na **trzy** stany: zdrowy, gruczolak (zmiana przedrakowa), rak. To naturalny problem **wieloklasowy**; dla uproszczenia można go sprowadzić do binarnego (rak / nie-rak).

```
table(y) # surowy study_condition w kohorcie ZellerG_2014
```

```
y
adenoma control    CRC
      42      61     53
```

Brak etykiet — poszukujemy **struktury** ukrytej w samych cechach.

Redukcja wymiarów

Sprowadzenie setek cech do kilku, przy zachowaniu głównej zmienności (np. PCA). Służy wizualizacji i odszumianiu.

Analiza skupień

Grupowanie próbek podobnych do siebie bez znajomości etykiet — np. odkrycie podtypów w kohorcie.

Odkrywanie podtypów

Analiza skupień na profilach ekspresji ujawniła podtypy molekularne raka piersi — bez wcześniejszych etykiet.

Mapa próbek

Redukcja wymiarów (PCA, UMAP) pozwala zobaczyć na płaszczyźnie, czy próbki układają się wg grup, serii czy ośrodków.

Skupienia to **hipotezy**, nie wnioski. Metoda zawsze zwróci jakiś podział — także dla danych bez realnej struktury. Trzeba go dopiero zweryfikować.

Zadanie główne

Uczenie **nadzorowane, klasyfikacyjne**: na podstawie składu mikrobiomu jelitowego przewidzieć, czy próbka pochodzi od pacjenta z rakiem jelita grubego (CRC), czy od osoby zdrowej.

Język i dane

Pojęcie	Znaczenie
próbka / obserwacja	pojedynczy pacjent (wiersz danych)
cecha (<i>feature</i>)	jedna zmienna objaśniająca, np. liczebność taksonu (kolumna)
zmienna celu (<i>target</i>)	wielkość przewidywana
macierz cech X	tabela: próbki $\times$ cechy
wektor celu y	kolumna etykiet
etykieta	wartość celu dla jednej próbki

Konwencja: X — macierz (wiele cech), y — pojedynczy wektor.

Model uczy się odwzorowania z cech (X) na cel (y).

- X ma wymiar $n \times p$: n próbek (wierszy), p cech (kolumn)
- y ma długość n : po jednej etykiecie na próbkę

Sytuacja $p \gg n$

W danych biologicznych cech (p) bywa znacznie więcej niż próbek (n).

Typ	Opis	Przykład
ciągła	wartość liczbową	liczebność taksonu
zliczeniowa	liczba całkowita nieujemna	liczba odczytów
kategoryczna	jedna z kilku kategorii	płeć, ośrodek
binarna	dwie kategorie	obecność/brak

Typ cechy decyduje o jej przygotowaniu — kategorie trzeba zakodować liczbowo.

Jak wyglądają nasze dane

	takson ₁	takson ₂	...	takson _p	grupa
pacjent ₁	0,032	0,000	...	0,001	CRC
pacjent ₂	0,008	0,041	...	0,000	zdrowy
pacjent ₃	0,000	0,000	...	0,012	CRC

macierz cech X (kolumny taksonów) | wektor celu y (kolumna grupa)

Liczne zera — typowe dla mikrobiomu, nie błąd.

Zanim cokolwiek policzymy — poznajemy kształt zbioru (kohorta CRC):

```
dim(X)      # wiersze = próbki, kolumny = taksony
```

```
[1] 156 652
```

Odczyt

- 156 próbek, 652 cechy $\Rightarrow p/n \approx 4,2$ — więcej cech niż próbek
- to sytuacja $p \gg n$: fundament trudności całego kursu

Względne liczebności jednej próbki sumują się do (prawie) 100%:

```
round(rowSums(X)[1:3], 1)  # suma udziałów na próbkę (%)
```

CCIS00146684ST-4-0	CCIS00281083ST-3-0	CCIS02124300ST-4-0
99.1	100.0	99.9

Drobne odchylenia od 100 to efekt zaokrągleń i frakcji niesklasyfikowanej.

Konsekwencja kompozycyjności

Wzrost jednego taksonu wymusza spadek innych — nawet gdy ich bezwzględna liczba się nie zmienia. Surowe udziały dają **korelacje pozorne**; stąd potrzeba przekształceń (do nich wrócimy w dalszej części kursu).

Zera — brak wykrycia, nie brak pomiaru

```
mean(as.matrix(X) == 0) * 100    # odsetek zer w całej macierzy
```

```
[1] 81.8
```

- ponad **cztery piąte** wartości to zera — macierz jest **rzadka**
- zero zwykle znaczy „taksonu nie wykryto u tego pacjenta”, nie „pomiar nieudany”
- to inny rodzaj zera niż brak danych — ma znaczenie biologiczne

Dlaczego to ważne

Interpretacja zer wpływa na dobór przekształceń i miar odległości. Potraktowanie ich jak braków danych byłoby błędem.

Jak model się uczy

Model to funkcja, która cechom próbki przypisuje przewidywanie:

Predykcja to wartość funkcji modelu obliczona dla cech próbki.

- x — wektor cech jednej próbki
- $\hat{y}$ — przewidywanie (etykieta lub prawdopodobieństwo)
- f — reguła wyuczona z danych treningowych

Uczenie = **dobór** f tak, by $\hat{y}$ było najbliższe y na treningu.


Idea

Definiujemy **funkcję straty** — miarę rozbieżności między $\hat{y}$ a y . Uczenie to poszukiwanie takich parametrów modelu, które tę stratę minimalizują.

- mała strata na treningu — model dobrze pamięta dane, które widział
- to jednak **nie** jest cel: chcemy skuteczności na *nowych* danych

Granica decyzyjna

Klasyfikator dzieli przestrzeń cech na obszary przypisane do klas:



Cel: granica najlepiej oddzielająca klasy — działająca też dla nowych punktów.

Niedouczenie

Model zbyt prosty — nie ujmuje wzorca. Słaby i na treningu, i na teście.

Dobre dopasowanie


Model ujmuje wzorzec, pomija szum. Dobry na treningu i na teście.

Przeuczenie

Model zbyt złożony — uczy się szumu. Znakomity na treningu, słaby na teście.

Cel: znaleźć złożoność **pośrednią** — wystarczającą, lecz nie nadmierną.

Krzywa błędu a złożoność modelu



Trening: błąd stale maleje. Test: **najpierw maleje, potem rośnie** — minimum = właściwa złożoność.


Dopasowujemy wielomiany rosnącego stopnia do tych samych danych; błąd (MSE) liczymy na treningu i na niezależnym teście.

```
set.seed(7)                                # y = sin(2*pi*x) + szum
x_tr <- sort(runif(50)); y_tr <- sin(2*pi*x_tr) + rnorm(50, 0, .35)
x_te <- sort(runif(2000)); y_te <- sin(2*pi*x_te) + rnorm(2000, 0, .35)
tab <- data.frame(stopien = c(1, 2, 3, 5, 9, 15))
for (i in seq_len(nrow(tab))) {
  m <- lm(y_tr ~ poly(x_tr, tab$stopien[i]))
  tab$blad_treningowy[i] <- mean((y_tr - predict(m))^2)
  tab$blad_testowy[i]    <- mean((y_te - predict(m, data.frame(x_tr = x_te)))^2)
}
print(round(tab, 3), row.names = FALSE)
```

stopien	blad_treningowy	blad_testowy
1	0.233	0.360
2	0.233	0.360
3	0.084	0.143
5	0.065	0.133
9	0.047	0.151
15	0.038	0.311

Błąd treningowy **stale maleje**; testowy osiąga minimum przy stopniu 5, a następnie znów rośnie.

Przeuczenie — ujęcie na wykresie



- błąd treningowy — stale w dół
- błąd testowy — krzywa U: spada, osiąga minimum, znów rośnie
- optimum = **pośrednia** złożoność

Niski błąd treningowy sam w sobie nic nie mówi o jakości modelu.

Obciążenie i wariancja

Błąd testowy składa się z **trzech części**, które się sumują:

- **obciążenie** — błąd systematyczny: model zbyt prosty, by uchwycić zależność
- **wariancja** — czułość modelu na konkretną próbkę treningową
- **błąd nieusuwalny** — szum w danych, którego żaden model nie usunie



Proste modele: duże obciążenie, mała wariancja (niedouczenie). Złożone: małe obciążenie, duża wariancja (przeuczenie).

Przekleństwo wymiarowości

Gdy cech jest bardzo wiele, intuicje z 2-3 wymiarów zawodzą. Liczymy stosunek najmniejszej do największej odległości między losowymi punktami.

```
set.seed(1)
# dla każdego p: 200 losowych punktów, stosunek min/max odległości
ratio <- function(p, n = 200) {
  D <- dist(matrix(runif(n * p), n, p))
  min(D) / max(D)
}
dims <- c(2, 10, 100, 1000)
data.frame(wymiary = dims, min_do_max = round(sapply(dims, ratio), 3))
```

wymiary	min_do_max
2	0.003
10	0.126
100	0.639
1000	0.849

Co się psuje

- „najbliższy sąsiad” przestaje być bliski
- przestrzeń jest prawie pusta — dane rzadkie
- łatwo o przypadkowy wzorzec

Co pomaga

- wybór i filtrowanie cech
- redukcja wymiarów (np. PCA)
- regularyzacja modelu

W sytuacji $p \gg n$ (nasz przypadek: 652 cechy, 156 próbek) przekleństwo wymiarowości to nie ciekawostka, lecz codzienny problem analizy.

Intuicja


Zamiast pozwolić modelowi dopasować się dowolnie, **karzemy** go za nadmierną złożoność — za zbyt duże lub zbyt liczne współczynniki. Każda cecha musi poprawiać dopasowanie na tyle, by przeważać karę za złożoność.

- efekt: prostsze, stabilniejsze modele, mniej podatne na przeuczenie
- część metod potrafi **wyzerować** nieistotne cechy (automatyczny wybór cech)
- siłę kary dobieramy jak każdy hiperparametr — na walidacji, nie na teście

To jedno z głównych narzędzi przeciw przekleństwu wymiarowości (szczegóły — dalej w kursie).

Elastyczność a interpretowalność

Modele różnią się **elastycznością** (jak złożone zależności oddają) i **interpretowalnością** (jak łatwo wyjaśnić ich decyzje) — zwykle jedno rośnie kosztem drugiego:




Interpretowalność w bioinformatyce — równie ważna jak trafność.

Uogólnienie

Wartość modelu mierzymy jego skutecznością na danych, których **nie widział** podczas uczenia.
Skuteczność na treningu niczego nie dowodzi.

Cały aparat kursu — podział na zbiory, walidacja krzyżowa, regularyzacja — służy **uczciwej ocenie uogólnienia**.

Proces analizy



Proces jest **iteracyjny** — ocena odsyła do przygotowania danych lub wyboru modelu.

Etap	Co się dzieje
Dane surowe	wczytanie, poznanie struktury, kontrola jakości
Przygotowanie	braki, przekształcenia, filtrowanie, kodowanie
Eksploracja	rozkłady, zależności, wizualizacja
Model	wybór metody, uczenie, strojenie
Ocena	skuteczność na danych niewidzianych
Interpretacja	wnioski, ograniczenia, komunikacja wyników


Przeciek danych (*data leakage*)

Wszystko, czego model się uczy, musi pochodzić **wyłącznie** ze zbioru treningowego. Gdy informacja ze zbioru testowego wpłynie na uczenie — choćby pośrednio — ocena staje się zawyżona i nieuczciwa.

Druga postać — przeciek celu (*target leakage*): wśród cech trafia się **przebrana etykieta** — zmienna, która staje się znana dopiero *po* poznaniu wyniku, więc w praktyce zdradza odpowiedź.

Przykład: metformina to lek na cukrzycę i zmienia skład mikrobiomu jelitowego. Model przewidujący cukrzycę z tego śladu osiągnie świetny wynik, lecz bezużyteczny — rozpoznaje nie chorobę, a fakt, że pacjent *już* ją leczy.

Podział na zbiory danych



- podział **przed** jakimkolwiek liczeniem
- zawsze zbiór **treningowy** i **testowy**
- **walidacyjny** (ramka przerywana) — tylko czasem, do wyboru i strojenia
- test — używany **raz**, na samym końcu

Problem

Gdy wybieramy model i stroimy go, patrząc na zbiór testowy, zaczynamy się do niego **dopasowywać** — i test przestaje być uczciwy. Dzieje się to nawet bez złej woli, przez wielokrotne zagłębienie.

- **trening** — model dobiera parametry
- **walidacja** — porównujemy modele i stroimy hiperparametry
- **test** — **jedno** końcowe spojrzenie, nietykany do końca

Przy małej liczbie próbek rolę walidacji przejmuje **walidacja krzyżowa**.

Walidacja krzyżowa — intuicja

- Mało próbek — nie dzielić tylko raz.
- Trening dzielony na k części; każda kolejno jako walidacja, reszta jako trening.

podział 1	walid.	trening	trening	trening
podział 2	trening	walid.	trening	trening
podział 3	trening	trening	walid.	trening
podział 4	trening	trening	trening	walid.

Skuteczność = **średnia** z k przebiegów. Każda próbka raz w walidacji.

Najczęstsze źródła przecieku — wszystkie polegają na użyciu informacji ze zbioru testowego **przed** oceną:

Błąd	Dlaczego to przeciek
normalizacja na całym zbiorze	parametry skalowania „widzą” test
wybór cech przed podziałem	cechy dobrane pod całość, w tym test
imputacja braków na całości	brakujące wartości uzupełnione z testu
dostrajanie wg wyniku testowego	test przestaje być niezależny

Reguła: **dziel najpierw**, licz potem. Każde przekształcenie dopasowuj tylko na treningu, a następnie zastosuj do testu.

Wyzwanie	Konsekwencja
$p \gg n$	więcej cech niż próbek $\Rightarrow$ łatwe przeuczenie; kluczowy wybór cech i regularyzacja
kompozycyjność	liczebności sumują się do 1 $\Rightarrow$ potrzebne przekształcenia
rzadkość	wiele zer (takson nieobecny u części pacjentów)
efekt serii (<i>batch effect</i>)	dane z różnych laboratoriów $\Rightarrow$ różnicę techniczną łatwo wziąć za biologiczną

Narzędzia i organizacja

Pracujemy **równolegle** w R i Pythonie.

R

Silna tradycja w statystyce i bioinformatyce;
bezpośredni dostęp do Bioconductora.

Python

Dominujący w uczeniu maszynowym; spójny
ekosystem **scikit-learn**.

Zadanie	R (tidymodels)	Python (scikit-learn)
przygotowanie	<code>recipes</code>	<code>Pipeline</code>
podział danych	<code>rsample</code>	<code>train_test_split</code>
modele	<code>parsnip</code>	estymatory
ocena	<code>yardstick</code>	<code>metrics</code>

Nazwy różne, **idee te same**: potok, podział, model, ocena.

Wynik, którego nie da się odtworzyć, nie jest wynikiem. Trzy nawyki od początku:

- ziarno losowe (`set.seed()`) — ten sam podział i wynik przy każdym uruchomieniu
- zapis wersji pakietów i R (`sessionInfo()`, `renv` / środowisko)
- raport generowany z kodu (Quarto / R Markdown / notatnik) — nie ręcznie

```
set.seed(42) # ustalamy ziarno PRZED losowym podziałem danych
```

Reguła praktyczna

Osoba trzecia, mając Państwa repozytorium, powinna odtworzyć wszystkie liczby z raportu. To praktyczny sprawdzian wiarygodności analizy.

Podsumowanie

Typowa pułapka

Łatwo zbudować model o skuteczności **100% na danych widzianych** i zaledwie **55% na nowych pacjentach**. Nie jest to model dobry — to przeuczenie.

Miarą sukcesu w tym kursie jest:

- skuteczność na danych, których model **nie widział**;
- **uczciwe** raportowanie tego wyniku.

- uczenie maszynowe = wyprowadzanie reguł z danych, aby przewidywać
- nadzorowane (z etykietami) vs nienadzorowane (bez); nasz problem to klasyfikacja
- dane: macierz cech X i wektor celu y ; u nas $p \gg n$
- główne zagrożenie: **przeuczenie**; zabezpieczenie: uczciwa ocena
- zasada nadrzędna: **model uczy się tylko z treningu**

- **Ćwiczenia:** środowisko pracy, repozytorium grupy, pozyskanie danych i poznanie struktury zbioru
- **Kolejny wykład:** przygotowanie danych do modelowania

Pytania?

Dziękuję za uwagę

dr inż. Bartosz Czech · bartosz.czech@upwr.edu.pl