ANALIZA DANYCH

Wykład 5: Ocena modelu



dr inż. Bartosz Czech

Katedra Genetyki · Uniwersytet Przyrodniczy we Wrocławiu

bartosz.czech@upwr.edu.pl

Plan i cel

Plan wykładu

1. Ocena modelu — od czego zacząć
2. Macierz pomyłek i miary: czułość, swoistość, precyzja, F1, MCC
3. Próg decyzyjny, krzywe ROC i PR, wybór progu
4. Niezrównoważenie klas
5. Kalibracja prawdopodobieństw
6. Analiza błędów
7. Więcej niż dwie klasy; błąd w regresji (MAE, RMSE)
8. Rzetelna ocena i raport

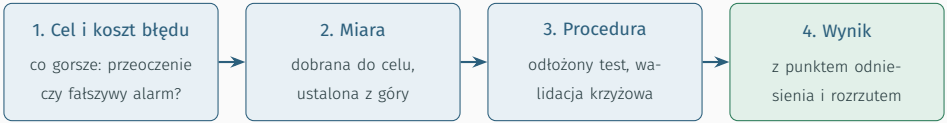
Cel

Umieć dobrać miarę do zadania, poprawnie ją odczytać i rozpoznać model, który dobrze wygląda na treningu, lecz **zawodzi** na nowych danych.

Ocena modelu — kolejność kroków

Ocena modelu (*model evaluation*)

Oszacowanie, jak model będzie działał na nowych danych, których nie widział przy uczeniu.



Ta sama predykcja bywa sukcesem albo porażką, zależnie od miary. Liczy się wynik na danych spoza treningu, a dobra ocena powtarza się przy innym podziale danych.

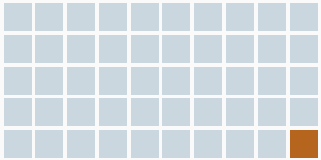
> Odwrotna kolejność — najpierw wiele miar, potem wybór tej, która wyszła najlepiej — to dopasowywanie oceny do wyniku.

Ograniczenia dokładności

Dokładność (*accuracy*)

Odsetek próbek, którym model przypisał właściwą klasę:

$$\text{dokładność} = \frac{\text{TP} + \text{TN}}{n}$$



1 kwadrat = 20 osób; pomarańczowy = 20 chorych

Przesiew (ang. *screening*) rzadkiej choroby: 1000 osób, 20 chorych (2%). „Model” uznaje wszystkich za zdrowych.

dokładność	980/1000 = 98%
wykryci chorzy	0 z 20

- Przy **niezrównoważonych** klasach **klasyfikator bazowy** (każdej próbce przypisuje klasę liczniejszą) ma wysoką dokładność, choć nie rozróżnia klas.
- Przeoczenie chorego i fałszywy alarm obniżają dokładność tak samo, choć kosztują różnie.

Macierz pomyłek

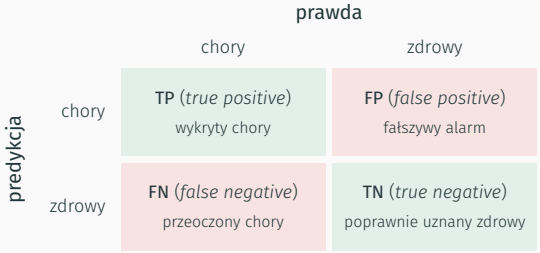
Model w R — prawdopodobieństwa i próg

Model przykładowy (ten sam co w W4): regresja logistyczna na **10 składowych PCA**; trening: 86 próbek, test: 28 (13 CRC, 15 kontroli); klasa dodatnia (ang. *positive class*): CRC.

```
# Ztr, Zte, ytr, yte: składowe PCA i etykiety z W4 (podział 75/25, filtr i PCA na treningu)
fit  <- glm(y ~ ., data = data.frame(y = ytr, Ztr), family = binomial)
p_te <- predict(fit, Zte, type = "response")   # P(CRC) dla każdej próbki testowej
pred <- ifelse(p_te >= 0.5, "CRC", "control")  # próg 0,5 zamienia P w decyzję
```

> Wiele modeli zwraca **prawdopodobieństwo**, nie gotową etykietę (ang. *label*). Dopiero **próg** (domyślnie 0,5) zamienia je w decyzję — i ten próg można zmieniać.

Budowa macierzy pomyłek



przekątna: trafienia
poza nią: pomyłki

W przykładzie (model z W4, próg 0,5):
TP 7 · FP 4 · FN 6 · TN 11

Macierz pomyłek (*confusion matrix*)

Tabela liczności: predykcje (wiersze) wobec prawdziwych klas (kolumny). Z tych czterech pól liczy się wszystkie miary przy ustalonym progu.

Klasa dodatnia

Większość miar jest **niesymetryczna**: TP i FN liczy się względem klasy nazywanej dodatnią (ang. *positive class*). Ta sama macierz z testu (wiersze: predykcja, kolumny: prawda; ramka: kolumna klasy dodatniej):

dodatnia = CRC

	control	CRC
control	11 TN	6 FN
CRC	4 FP	7 TP

czułość $= 7/13 =$ 0,54

dodatnia = control

	control	CRC
control	11 TP	6 FP
CRC	4 FN	7 TN

czułość $= 11/15 =$ 0,73

Dodatnia to zwykle klasa rzadsza i ważniejsza (chory, nowotwór). Należy ją zawsze podawać — inaczej „czułość 0,7” jest niejednoznaczna.

Macierz pomyłek w R

Model logistyczny z początku sekcji, próg 0,5; funkcja `confusionMatrix` z pakietu `caret`:

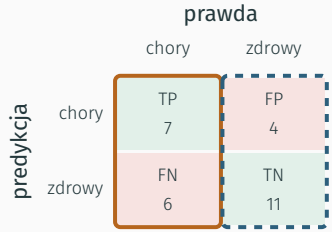
```
library(caret)
pred <- factor(ifelse(p_te >= 0.5, "CRC", "control"),
               levels = c("control", "CRC"))
cm <- confusionMatrix(pred, yte, positive = "CRC",   # klasa dodatnia
                      mode = "everything")           # także precyzja i F1
cm$table                                             # sama macierz pomyłek
```

```
          Reference
Prediction control CRC
   control      11   6
   CRC           4   7
```

> Na przekątnej trafienia (11 zdrowych, 7 chorych), poza nią pomyłki (4 fałszywe alarmy, 6 przeoczonych chorych). Wiersze: predykcja (`Prediction`), kolumny: prawda (`Reference`).

Miary przy ustalonym progu

Miary liczone kolumnami: czułość i swoistość



Czułość (*sensitivity, recall*) — jaka część chorych zostaje wykryta:

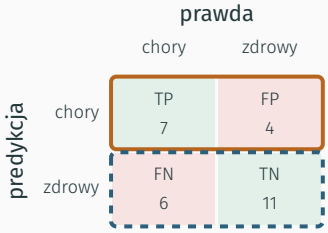
$$\frac{\text{TP}}{\text{TP} + \text{FN}} = \frac{7}{13} = 0{,}54$$

Swoistość (*specificity*) — jaka część zdrowych zostaje poprawnie uznana za zdrowych:

$$\frac{\text{TN}}{\text{TN} + \text{FP}} = \frac{11}{15} = 0{,}73$$

Mianownik to **rzeczywista** grupa (kolumna macierzy), więc obie miary nie zależą od częstości choroby w próbie. Odpowiadają na pytanie badającego: „ilu chorych wykryję i ilu zdrowych poprawnie uznam za zdrowych”.

Miary liczone wierszami: precyzja i NPV



Precyzja (*precision*, PPV) — ile wyników dodatnich jest trafnych:

$$\frac{\text{TP}}{\text{TP} + \text{FP}} = \frac{7}{11} = 0{,}64$$

NPV (*negative predictive value*) — ile wyników ujemnych jest trafnych:

$$\frac{\text{TN}}{\text{TN} + \text{FN}} = \frac{11}{17} = 0{,}65$$

Mianownik to **wyniki** modelu (wiersz macierzy). Pytanie pacjenta z wynikiem dodatnim: „czy naprawdę jestem chory?”. Dokładność łączy wszystko: $(7 + 11)/28 = 0{,}64$.

Precyzja a częstość choroby

Ten sam test (czułość 0,9, swoistość 0,9) zastosowany u 1000 osób w dwóch populacjach:

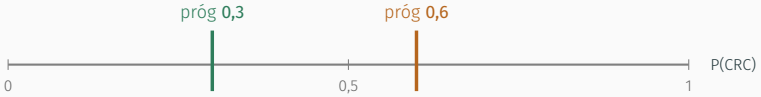
Populacja	Chorzy	Zdrowi	Wynik dodatni u chorych	Wynik dodatni u zdrowych	Precyzja
połowa chorych	500	500	450	50	450/500 = 0,90
2% chorych	20	980	18	98	18/116 = 0,16

- Test daje fałszywy wynik dodatni u 10% zdrowych. Przy rzadkiej chorobie to 98 osób, więcej niż wszystkich chorych, więc większość wyników dodatnich jest fałszywa.
- **Czułość i swoistość** nie zależą od częstości choroby (ang. *prevalence*); **precyzja i NPV** — zależą.

Precyzji z badania, w którym chorych jest połowa, nie przenosi się na przesiew populacyjny.

Kompromis precyzji i czułości

Model daje każdej próbce **P(CRC)**, liczbę od 0 do 1. **Próg** decyduje, od jakiego P próbka dostaje wynik dodatni, czyli klasę CRC (P $\geq$ próg). Ten sam model, dwa progi (test: 13 próbek CRC, 15 kontroli):



	wyniki dodatnie	w tym trafne (TP)	czułość	precyzja
próg 0,3	18	10 z 13	0,77	0,56
próg 0,6	6	5 z 13	0,38	0,83

- Niski próg: wykrywa więcej chorych, ale wśród wyników dodatnich jest więcej fałszywych.
- Wysoki próg: wyniki dodatnie są trafniejsze, ale część chorych zostaje przeoczona. Potrzebna miara łącząca obie.

Miara F1

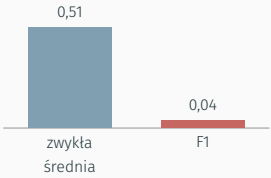
F1 (*F1 score*)

Średnia harmoniczna precyzji (P) i czułości (R):

$$F_1 = \frac{2\,P\,R}{P + R}$$

Wysoka tylko wtedy, gdy **obie** są wysokie. W przykładzie:
$2 \cdot 0{,}64 \cdot 0{,}54 / 1{,}18 = 0{,}58$.

P = 1, R = 0,02 (1 chory z 50)



Zalety

- Obniża wynik, gdy jedna składowa jest bardzo niska
- Skupia się na klasie dodatniej

Wady

- Pomija TN (poprawnie uznanych zdrowych)
- Zależy od częstości klasy dodatniej

Miary uwzględniające obie klasy

Dokładność zbalansowana (*balanced accuracy*)

$$\text{BA} = \frac{\text{czułość} + \text{swoistość}}{2}$$

Obie klasy ważą równo; 0,5 to poziom losowy.

MCC (*Matthews correlation coefficient*)

Korelacja między predykcją a prawdą, liczona z całej macierzy pomyłek: od -1 przez 0 (jak losowo) do $+1$ (bez pomyłek).

	dokładność	BA	MCC
„zawsze zdrowy” (przesiew, 2% chorych)	0,98	0,50	0
model przykładowy (test)	0,64	0,64	0,28

Klasyfikator bazowy nie uzyskuje zawyżonych wartości BA ani MCC. Wydruk `caret` podaje też kappę Cohena — zwykle bliską MCC.

Miary klasyfikacji w caret

```
cm        # wydruk całego obiektu
          # (bez macierzy i pustych wierszy)
```

```
               Accuracy : 0.6429
                 95% CI : (0.4407, 0.8136)
    No Information Rate : 0.5357
    P-Value [Acc > NIR] : 0.1720
                  Kappa : 0.2746
 Mcnemar's Test P-Value : 0.7518
            Sensitivity : 0.5385
            Specificity : 0.7333
```

```
# MCC: pakiet ModelMetrics (instalowany z caret)
ModelMetrics::mcc(as.numeric(yte == "CRC"), p_te,
                  cutoff = 0.5)
```

```
[1] 0.2775478
```

```
      Pos Pred Value : 0.6364
      Neg Pred Value : 0.6471
           Precision : 0.6364
              Recall : 0.5385
                  F1 : 0.5833
          Prevalence : 0.4643
      Detection Rate : 0.2500
Detection Prevalence : 0.3929
   Balanced Accuracy : 0.6359
    'Positive' Class : CRC
```

Czułość (`Sensitivity`), swoistość, precyzja (`Pos Pred Value`), NPV, F1, dokładność zbalansowana i kappa — bez ręcznego liczenia.

Miary klasyfikacji na danych przykładowych

Miara (w wydruku)	Wartość	Odczyt
czułość (`Sensitivity`)	0,54	wykrywa ok. połowę chorych, 46% przeocza
swoistość (`Specificity`)	0,73	poprawnie uznaje za zdrowych ok. trzech na czterech zdrowych
precyzja (`Precision`)	0,64	mniej więcej co trzeci wynik „CRC” jest fałszywy
F1	0,58	kompromis precyzji i czułości, obniżony przez czułość
dokładność zbalansowana	0,64	bliska surowej (0,64), bo klasy w teście są niemal równoliczne
MCC / kappa	0,28 / 0,27	lepiej niż przypadek, ale wyraźnie bliżej zera niż jedynki

Model faworyzuje klasę zdrową: jego najsłabszą stroną jest wykrywanie chorych, czyli to, na czym zależy najbardziej. Sama dokładność 0,64 tej asymetrii nie pokazuje.

Te same miary w Pythonie

```
# Z_tr, Z_te, y_tr, y_te: te same dane co w R (z W4)
import numpy as np; from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, matthews_corrcoef
model = LogisticRegression(C=np.inf).fit(Z_tr, y_tr)  # y: 1 = CRC; bez kary, jak glm
p_te = model.predict_proba(Z_te)[:, 1]; pred = (p_te >= 0.5).astype(int)   # P(CRC): kolumna klasy 1; próg 0,5
print(classification_report(y_te, pred, target_names=["control", "CRC"], digits=3))
print(round(matthews_corrcoef(y_te, pred), 3))
```

```
              precision    recall  f1-score   support

     control      0.647     0.733     0.688        15
         CRC      0.636     0.538     0.583        13

    accuracy                          0.643        28
   macro avg      0.642     0.636     0.635        28
weighted avg      0.642     0.643     0.639        28
0.278
```

> Te same liczby co w R. Wiersz **CRC**: precyzja, czułość i F1 klasy dodatniej; `recall` wiersza `control` to swoistość, `macro avg` recall — dokładność zbalansowana.

Próg i krzywe ROC/PR

Próg decyzyjny a koszt błędu

Próg 0,5 to tylko umowa. Przesunięcie progu **zamienia** jeden rodzaj błędu na drugi — przy tym samym modelu:



Drogi FN (przeoczony chory)

Onkologia, przesiew: opóźniona terapia ⇒ próg się **obniża**.

Drogi FP (fałszywy alarm)

Kwalifikacja do agresywnego leczenia ⇒ próg się **podnosi**.

> Domyślne 0,5 zakłada, że przeoczenie i fałszywy alarm kosztują **tyle samo**. Próg to decyzja kliniczna, nie czysto statystyczna.

Przesuwanie progu w R

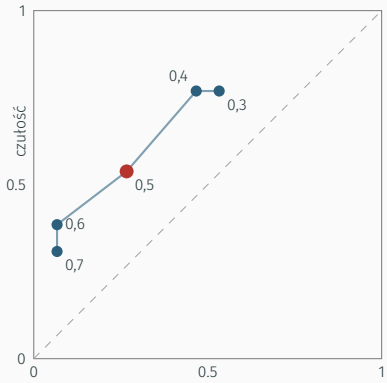
`roc` (pakiet pROC) zapisuje czułość i swoistość przy każdym progu, `coords` je odczytuje:

```
library(pROC)
r <- roc(yte, p_te, levels = c("control", "CRC"), direction = "<")
coords(r, x = c(0.3, 0.4, 0.5, 0.6, 0.7),     # progi
       ret = c("threshold", "sensitivity", "specificity", "precision", "tp"))
```

```
  threshold sensitivity specificity precision tp
1       0.3   0.7692308   0.4666667 0.5555556 10
2       0.4   0.7692308   0.5333333 0.5882353 10
3       0.5   0.5384615   0.7333333 0.6363636  7
4       0.6   0.3846154   0.9333333 0.8333333  5
5       0.7   0.3076923   0.9333333 0.8000000  4
```

> Próg 0,4: 10 z 13 chorych wykrytych (`tp`), ale pomyłki u prawie połowy zdrowych. Próg 0,7: rzadkie pomyłki u zdrowych, tylko 4 wykrytych chorych.

Od tabeli progów do krzywej ROC



Każdy wiersz tabeli progów to **jeden punkt**: na osi poziomej 1 — swoistość, na pionowej czułość.

- Próg 0,7 (lewy dół): mało fałszywych alarmów, mało wykrytych chorych.
- Próg 0,3 (prawa góra): dużo wykrytych chorych, dużo fałszywych alarmów.
- **Wszystkie** progi naraz dają krzywą ROC.

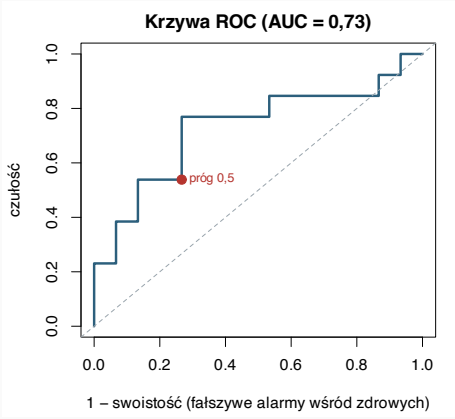
Krzywa ROC i AUC

Zamiast jednego progu — **wszystkie** progi naraz:

Krzywa ROC (*receiver operating characteristic*)

Wykres czułości względem odsetka zdrowych błędnie uznanych za chorych (1 − swoistość, ang. *false positive rate*) przy wszystkich progach. Pole pod krzywą (*AUC, area under the curve*) streszcza ją jedną liczbą.

- Każdy **punkt** krzywej to jeden próg; czerwony punkt — próg 0,5.
- Przekątna = model losowy (AUC 0,5); ideał dąży do lewego górnego rogu (AUC 1).
- Punkt **roboczy** (ang. *operating point*) wybiera się świadomie: bliżej lewej, gdy liczy się swoistość; wyżej, gdy czułość.



AUC w R i jego interpretacja

```r
auc(r)                          # r: obiekt roc z tabeli progów
```

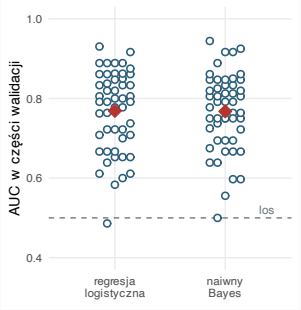
```
Area under the curve: 0.7282
```

```python
roc_auc_score(y_te, p_te)       # Python: 0.728
```



- AUC to szansa, że losowy **chory** dostanie wyższe P niż losowy **zdrowy**; model losowy: 0,5.
- Ocenia **uporządkowanie** próbek, nie wartości prawdopodobieństw ani jeden próg.

Niepewność AUC



- AUC z jednego testu (28 próbek) to **jedno** losowanie: inny podział dałby inne AUC.
- Powtarzana walidacja krzyżowa (10 razy po 5 części, W4) daje 50 wartości AUC: od **0,49** do **0,93**, średnio **0,77** (kółko — jedna część, romb — średnia).
- Na teście regresja logistyczna (0,73) wyprzedza naiwnego Bayesa (0,68), ale w tych samych 50 częściach oba mają średnio **0,77**.

```
ctrl <- trainControl(method = "repeatedcv", number = 5, repeats = 10,       # 10 x 5 części
                     classProbs = TRUE, summaryFunction = twoClassSummary)  # AUC w każdej części
set.seed(7); fit <- train(x = Xtr, y = ytr, method = "glm", preProcess = "pca", metric = "ROC", trControl = ctrl)
```

Raportuje się średnią **i** rozrzut. Różnica mniejsza niż rozrzut nie dowodzi, że któryś model jest lepszy; spośród równorzędnych wybiera się prostszy.

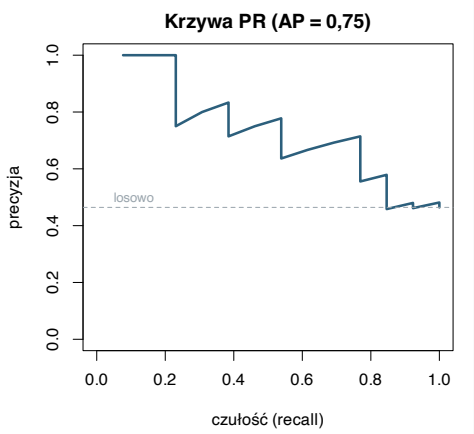
Krzywa precyzja–czułość

Druga ocena obejmująca wszystkie progi — skupiona na klasie **dodatniej**:

Krzywa PR (*precision–recall curve*)

Precyzja (pionowo) względem czułości (poziomo) przy wszystkich progach. **Średnia precyzja** (*AP, average precision*) to pole pod tą krzywą — jedna liczba, tak jak AUC dla krzywej ROC.

- Linia bazowa (losowa; ang. *baseline*) leży na wysokości **udziału** klasy dodatniej, nie na 0,5.
- W przykładzie: **AP 0,75** wobec linii bazowej **0,46** (udział CRC w teście).
- Przy **rzadkiej** klasie ROC bywa zbyt optymistyczna, PR to pokazuje — wtedy podaje się obie.

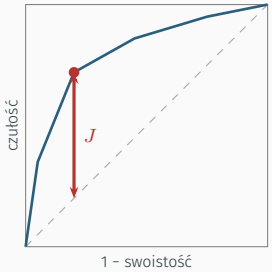


Wybór progu

Indeks Youdena (*Youden's index*)

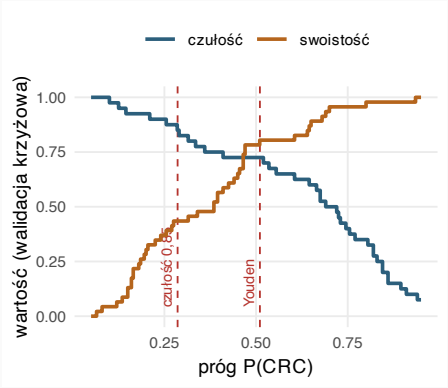
$$J = \text{czułość} + \text{swoistość} - 1$$

Od 0 (test bezużyteczny) do 1 (idealny). Próg o największym J to punkt ROC **najdalej w pionie** od przekątnej.



- Youden waży czułość i swoistość **jednakowo**.
- **Próg przy wymaganej czułości**: najwyższy próg, przy którym czułość $\geq$ np. 0,85 — gdy przeoczenie kosztuje więcej niż fałszywy alarm.
- Próg dobiera się na **treningu** (predykcje z walidacji krzyżowej), a sprawdza raz na teście.

Wybór progu na danych przykładowych



Progi wybrane na treningu (predykcje z walidacji krzyżowej, rycina), sprawdzone raz na teście:

Próg	Czułość	Swoistość	Wykryte CRC (z 13)	Fałszywe alarmy (z 15)
0,51 (Youden)	0,54	0,80	7	3
0,29 (czułość $\geq$ 0,85)	0,77	0,47	10	8

- Próg 0,29 wykrywa więcej przypadków CRC kosztem fałszywych alarmów — wybór dla przesiewu.
- Na teście czułość wyniosła 0,77, nie 0,85: wynik z walidacji nie przenosi się na test jeden do jednego.

Progu nie dobiera się na teście: test przestaje być niezależny, a czułość i swoistość są wtedy zawyżone.

Niezrównoważenie klas

Niezrównoważenie klas — źródła i skutki

Niezrównoważenie klas (*class imbalance*)

Jedna klasa jest wyraźnie mniej liczna. W biologii to często klasa „interesująca”: rzadka choroba, wariant, nawrót, odpowiedź na terapię.



- Model, który pomija klasę rzadką, i tak ma wysoką dokładność, dlatego proces uczenia sprzyja takiemu rozwiązaniu.
- W badaniu kliniczno-kontrolnym (ang. *case–control study*) proporcję klas ustala badacz.

Objaw: wysoka dokładność, czułość klasy rzadkiej bliska zera. Należy zawsze sprawdzać miary dla każdej klasy.

Strategie przy niezrównoważeniu

1. Dobór progu

niższy próg, by wykrywać więcej przypadków klasy rzadkiej

✓ model i dane bez zmian

2. Wagi klas

pomyłka na klasie rzadkiej liczy się przy uczeniu mocniej

✓ dane bez zmian

```
LogisticRegression(class_weight="balanced")   # Python: wagi odwrotne do częstości klas
```

```
w <- ifelse(ytr == "CRC", 1 / mean(ytr == "CRC"), 1 / mean(ytr == "control"))
train(x = Ztr, y = ytr, method = "glm", weights = w)   # R (caret): wagi próbek
```

Zwykle wystarczy dobór progu i miary liczone dla każdej klasy (dokładność zbalansowana, MCC, krzywa PR).

Kalibracja

Znaczenie kalibracji

AUC mówi, czy model dobrze **porządkuje** próbki, a nie, czy jego liczby to **prawdziwe** P.

Kalibracja (*calibration*)

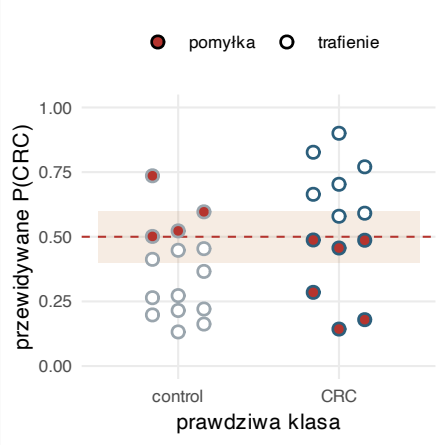
Zgodność przewidywanych prawdopodobieństw z obserwowanymi częstościami: gdy model orzeka „70% szans na chorobę” dla grupy pacjentów, naprawdę choruje ok. 70% z nich.

	Dyskryminacja (ang. *discrimination*)	**Kalibracja**
pytanie	czy porządkuje chorych nad zdrowymi	czy liczby to prawdziwe P
ocena	AUC, AP	wykres kalibracji (ang. *calibration plot*)
po co	porównanie, ranking	decyzje oparte na ryzyku

Model o wysokim AUC bywa źle skalibrowany. Jeśli wykorzystuje się samo prawdopodobieństwo (np. szacowanie ryzyka), sprawdza się obie własności.

Analiza błędów

Analiza błędów na danych przykładowych



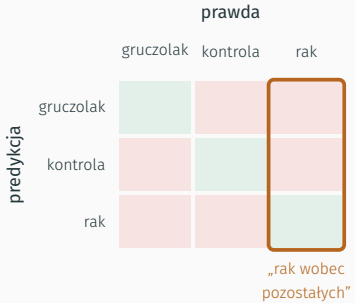
Analiza błędów (*error analysis*)

Przegląd próbek klasyfikowanych błędnie: gdzie leżą ich przewidywane P i czym różnią się od trafnych.

- Mediana P(CRC): **0,37** u kontroli, **0,58** u chorych — rozkłady wyraźnie się nakładają.
- 10 pomyłek; 6 z nich w pasie 0,4–0,6: **niepewne**, zmieni je drobna zmiana progu lub danych.
- 4 pomyłki **pewne** (P poniżej 0,3 lub powyżej 0,7): trzy to przypadki CRC we **wczesnym stadium** (I–II), jedna to kontrola o bardzo małej liczbie odczytów — warto sprawdzić jakość próbek i podgrupy.

Ocena wieloklasowa i regresja

Klasyfikacja wieloklasowa



Macierz $k \times k$: na przekątnej trafienia, poza nią widać, **które** klasy się mylą.

Miary liczy się **dla każdej klasy**: „ta klasa wobec pozostałych” (ang. *one-vs-rest*). Jedną liczbę daje uśrednianie:

- **makro**: zwykła średnia z F1 wszystkich klas — każda klasa waży tyle samo
- **ważone**: wagą jest liczebność klasy
- **mikro**: przy jednej etykiecie na próbkę = dokładność

Należy zawsze podawać wariant uśredniania. Analiza, które pary klas się mylą, bywa cenniejsza niż jedna liczba.

Ocena wieloklasowa w R

Pełna kohorta ZellerG (42 gruczolaki, 61 kontroli, 53 CRC; test 38); k-NN ($k = 5$) na 10 składowych PCA:

```
# Z3tr, Z3te, y3tr, y3te: 3 klasy; podział 75/25, filtr i PCA jak dla 2 klas
library(class); set.seed(1)                          # ziarno: remisy głosów k-NN
pr3 <- knn(Z3tr, Z3te, y3tr, k = 5)                  # k-NN, k = 5
cm3 <- confusionMatrix(pr3, y3te, mode = "everything")
cm3$table; round(cm3$byClass[, c("Sensitivity", "Precision", "F1")], 3)
# Python: print(classification_report(y3_te, pred3))
```

```
          Reference
Prediction adenoma control CRC
  adenoma        2       4   5
  control        7       9   5
  CRC            1       2   3
```

```
                     Sensitivity Precision    F1
Class: adenoma             0.200     0.182 0.190
Class: control             0.600     0.429 0.500
Class: CRC                 0.231     0.500 0.316
```

Najlepiej rozpoznana kontrola (czułość 0,60), najsłabiej gruczolak i rak. Dokładność 0,37, makro-F1 0,34. Punkt odniesienia: klasyfikator bazowy (każdej próbce „kontrola”) ma dokładność 0,39 — k-NN nie jest od niego lepszy.

Miary błędu regresji: MAE i RMSE

MAE (*mean absolute error*)

$$\text{MAE} = \frac{1}{n}\sum_i |y_i - \hat{y}_i|$$

Przeciętna wielkość pomyłki, w jednostkach celu.

RMSE (W4)

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_i (y_i - \hat{y}_i)^2}$$

Kwadrat mocniej waży duże błędy.

```
age <- cd$age                                  # wiek z metadanych
fitr <- lm(age ~ ., data = data.frame(age = age[tr], Ztr))   # 10 składowych, jak w W4
prr <- predict(fitr, Zte)
c(RMSE = RMSE(prr, age[idx_test]), MAE = MAE(prr, age[idx_test]))   # caret: 10.54  8.69
```

```
mean_absolute_error(age_te, prr), root_mean_squared_error(age_te, prr)   # age_te = age[idx_test]
```

Typowa pomyłka 8,7 roku (MAE), RMSE 10,5; stosunek 1,2 — bez wyjątkowo dużych pomyłek. Punkt odniesienia: każdemu średni wiek z treningu (63 lata) daje MAE 8,0 i RMSE 10,3 — model jest gorszy od średniej, więc składowe mikrobiomu nie przewidują wieku.

Rzetelność oceny

Miara a procedura oceny

Nawet dobrze dobrana miara wprowadza w błąd, jeśli zostanie wyznaczona **źle**:

× procedura	✓ zamiast tego
miara na treningu — zwykle zawyżona	miara na danych spoza treningu
jeden mały test — wynik zależny od losu podziału	rozrzut w powtarzanej walidacji krzyżowej
próg, cechy dobierane na teście — przeciek	dobór na treningu, test raz na końcu

> Ocena jest tyle warta, ile **procedura**, która ją wyznaczyła.

Podsumowanie

Wybór miary oceny

Sytuacja	Miara
klasy zrównoważone, równy koszt błędu	dokładność
klasy niezrównoważone, obie klasy ważne	MCC, dokładność zbalansowana
liczy się wykrywanie klasy dodatniej	F1 (precyzja i czułość)
nie wolno przeoczyć chorego	czułość
fałszywy alarm jest kosztowny	precyzja, swoistość
ocena niezależna od progu	AUC (ROC), AP (PR) — PR przy rzadkiej klasie
decyzje na prawdopodobieństwie	kalibracja (czy P to prawdziwe ryzyko)
wiele klas	macierz $k \times k$, jawny wariant uśredniania

Najpierw cel i koszt błędu, potem miara. Zawsze zestaw miar i rozrzut oceny w walidacji krzyżowej, nie jedna liczba.

Raport z oceny modelu

Element raportu	Na danych przykładowych	R / Python
klasa dodatnia i próg	CRC; próg 0,5 (Youden z CV: 0,51)	`positive = "CRC"`, `coords()`
miara na danych spoza treningu	AUC 0,73; czułość 0,54, swoistość 0,73	`auc()`, `confusionMatrix()` / `roc_auc_score`, `classification_report`
punkt odniesienia	klasyfikator bazowy: dokładność 0,54; AUC losowe 0,5	`No Information Rate` w wydruku `confusionMatrix`
rozrzut w walidacji krzyżowej	AUC części 0,49–0,93, średnio 0,77	`train(metric = "ROC")` / `cross_val_score`
wiele klas	macierz $k \times k$, makro-F1 0,34; dokładność 0,37 wobec 0,39 klasyfikatora bazowego	`byClass` / `classification_report`

Raport nie podaje jednej liczby, lecz miarę na teście, punkt odniesienia i rozrzut. Różnica między modelami mniejsza niż rozrzut nie jest dowodem przewagi.

Typowe pułapki w ocenie modelu

× pułapka	✓ zamiast tego
sama dokładność przy niezrównoważonych klasach	BA, MCC, miary dla każdej klasy
jedna miara	zestaw miar dobrany do kosztu błędu
sztywny próg 0,5	próg z walidacji krzyżowej (Youden, wymagana czułość)
samo AUC przy decyzjach na P	sprawdzić też kalibrację
różnica mniejsza niż rozrzut jako przewaga	porównanie w tych samych częściach CV
zerowy błąd treningowy jako sukces	sygnał przeuczenia

Lista kontrolna przed oddaniem projektu lub wysłaniem pracy.

Do zapamiętania

- Najpierw cel i koszt błędu, potem miara; dokładność bywa **myląca**
- Macierz pomyłek: kolumnami **czułość, swoistość**, wierszami **precyzja, NPV**; zawsze z klasą dodatnią
- Przy niezrównoważeniu: **dokładność zbalansowana, MCC**, krzywa **PR**
- **ROC/AUC** ocenia ranking we wszystkich progach; AUC z jednego testu to jedno losowanie
- Próg dobiera się na predykcjach z walidacji krzyżowej, sprawdza raz na teście
- **Kalibracja**: czy P to prawdziwe ryzyko; w regresji **MAE** obok RMSE

Jedna myśl

Raport z oceny to zestaw miar, punkt odniesienia i rozrzut — nie jedna liczba.

Literatura

- James, Witten, Hastie, Tibshirani. *An Introduction to Statistical Learning* — rozdz. 2 (obciążenie–wariancja, ang. *bias–variance*), 4 (ROC, macierz pomyłek), 5 (walidacja). Wydania R i Python (ISLP): statlearning.com.
- Boehmke, Greenwell. *Hands-On Machine Learning with R* — miary skuteczności i przeuczenie: bradleyboehmke.github.io/HOML.
- Robin i in. (2011). pROC: an open-source package for R and S+ to analyze and compare ROC curves. *BMC Bioinformatics* 12:77; dokumentacja: cran.r-project.org/package=pROC.
- Kuhn. *The caret Package* — `confusionMatrix`, `trainControl`, miary: topepo.github.io/caret.
- scikit-learn: *Metrics and scoring* — scikit-learn.org/stable/modules/model_evaluation.html.

Na następny wykład

Wykład 6: Modele złożone i cechy

- Drzewa decyzyjne (ang. *decision trees*) i lasy losowe (ang. *random forests*) — łączenie wielu drzew
- Boosting — uczenie na błędach poprzednich modeli
- Maszyny wektorów nośnych (ang. *support vector machines*) — granica o największym marginesie
- Regularyzacja i wybór cech (ang. *feature selection*) przy dużej liczbie cech

Dziękuję za uwagę

dr inż. Bartosz Czech · bartosz.czech@upwr.edu.pl