BIOSTATYSTYKA

Wykład 5: Testy statystyczne II

dr inż. Bartosz Czech

Katedra Genetyki · Uniwersytet Przyrodniczy we Wrocławiu

bartosz.czech@upwr.edu.pl

Plan wykładu

1. Test t sparowany: pomiary w parach
2. Dane kategoryczne: chi-kwadrat, test Fishera i test McNemara
3. Testy nieparametryczne (rangi)
4. Drzewo wyboru testu — zestawienie metod z wykładów 3–5
5. Testy w praktyce — kod i wynik w R

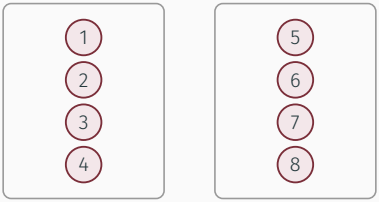
Cel

Domknąć rodzinę testów porównujących, zrozumieć, od czego zależy wynik każdego z nich, i zbudować schemat decyzyjny: jaki test do jakiego typu danych.

1. Test t sparowany

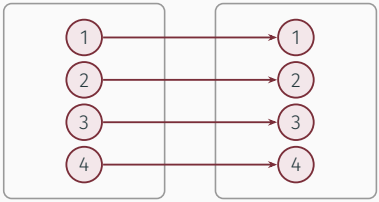
Dane zależne: pomiary sparowane

próby niezależne



różne osobniki, każdy mierzony raz

próby sparowane



te same osobniki, dwa pomiary; liczy się różnica w parze

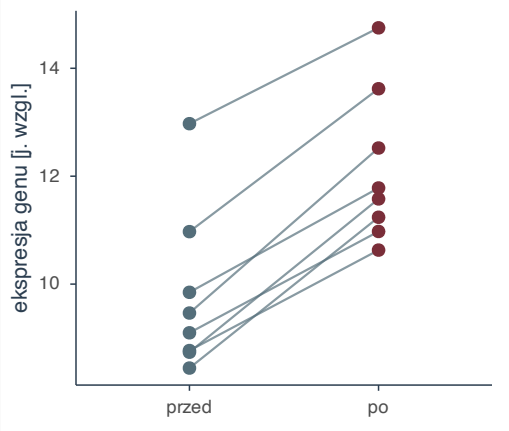
- Typowe pary: przed/po, lewa/prawa strona, bliźnięta, tkanka zdrowa i chora tego samego pacjenta
- Przykład: ekspresja genu przed i po podaniu induktora w *tych samych* hodowlach

Sparowanie: mniej zmienności międzyosobniczej

- Analizuje się **różnicę** między dwoma pomiarami tego samego osobnika
- Znika zmienność międzyosobnicza (różnice poziomu wyjściowego między hodowlami)
- Zostaje efekt zabiegu i niewielki rozrzut różnic, stąd **większa moc** testu

Intuicja

Każdy osobnik jest sam dla siebie kontrolą.



Test t sparowany i jego składniki

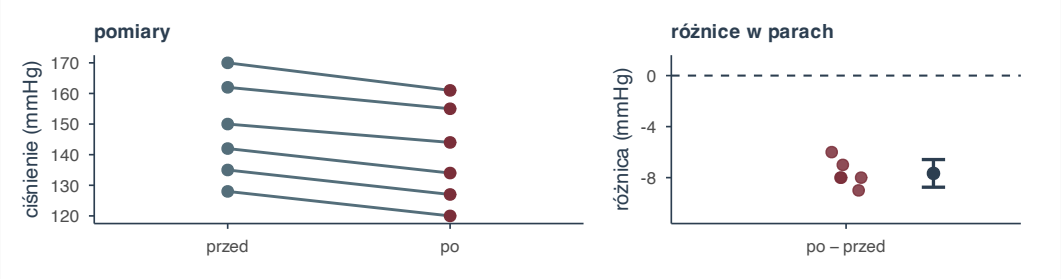
Test t sparowany (*paired t-test*)

Test t jednej próby zastosowany do różnic między dwoma pomiarami w parze; H_0: średnia różnica w populacji wynosi zero. Szumem jest rozrzut różnic, nie pomiarów.

$$t = \frac{\text{średnia różnic}}{\text{błąd standardowy średniej różnic}}$$

Gdy rośnie...	wartość $\lvert t \rvert$...	bo...
średnia różnica (efekt zabiegu)	rośnie	większy sygnał
rozrzut różnic	maleje	większy szum
liczba par	rośnie	więcej par daje mniejszy błąd standardowy
podobieństwo pomiarów w parze	rośnie	różnice mają mniejszy rozrzut

Test sparowany — przykład ciśnienia



- Sygnał: ciśnienie spadło średnio o 7,7 mmHg
- Szum: różnice prawie jednakowe (SD 1,0 mmHg), choć pacjenci różnią się ciśnieniem wyjściowym (SD 16,1 mmHg)
- Test sparowany: $t = -18{,}2$, df $= 5$, $p < 0{,}001$
- Te same liczby błędnie jako dwie grupy niezależne (Welch): $t = -0{,}8$, $p = 0{,}43$ – efektu nie wykryto

Założenia testu sparowanego

- **Niezależność par**: różne pary nie wpływają na siebie; pomiary w parze są zależne z założenia
- **Rozkład różnic** zbliżony do normalnego (nie rozkład samych pomiarów); oceniać wykresem kwantylowym różnic
- Brak silnie odstających różnic
- Gdy rozkład różnic jest wyraźnie nienormalny: test Wilcoxona dla par (porównuje kolejność różnic zamiast ich wartości)

Dane sparowane i niezależne

Reguła

Sparowanie wynika z planu: każda obserwacja z jednej grupy ma jednoznacznie przypisany odpowiednik w drugiej — ten sam osobnik (przed/po) albo para dobrana przed doświadczeniem (bliźnięta, rodzeństwo z miotu, lewa/prawa strona). Bez takiego przypisania dane są niezależne.

- Analizy sparowanej nie wybiera się po zebraniu danych (dla mniejszego p); o sparowaniu decyduje plan, wybierany m.in. po to, by zwiększyć moc (wykład 3)
- Sprawdzian: czy da się wskazać, który pomiar z pierwszej grupy odpowiada któremu z drugiej?
- W R: `t.test(po, przed, paired = TRUE)`

Test t sparowany: przykładowe doświadczenia

- **Ten sam osobnik przed i po**: stężenie glukozy we krwi 15 szczurów przed podaniem insuliny i 2 godziny po nim
- **Dwie tkanki tego samego pacjenta**: ekspresja genu w guzie i w zdrowej tkance pobranej obok, u 12 pacjentów
- **Pary dobrane w planie**: plon dwóch odmian pszenicy wysianych obok siebie na 10 polach; każde pole tworzy parę, bo obie odmiany rosną na tej samej glebie
- **Lewa i prawa strona**: na jeden liść każdej rośliny nanosi się preparat, na drugi sam rozpuszczalnik; mierzy się wielkość plamy porażenia

Wspólna cecha

Każdy pomiar z jednej grupy ma swój odpowiednik w drugiej, a test analizuje różnice w parach. Rozkład różnic powinien być zbliżony do normalnego.

2. Dane kategoryczne

Zmienne kategoryczne

- Zmienna zależna nie jest liczbą, lecz **kategorią**: przeżył/zginął, oporny/wrażliwy, genotyp
- Analizuje się **liczebności** kategorii, a nie średnie
- Dwa pytania: czy obserwowane proporcje odbiegają od **oczekiwanych** (test zgodności) albo czy dwie cechy są **powiązane** (test niezależności)

Narzędzie

Rodzina testów **chi-kwadrat** (*chi-squared*), **dokładny test Fishera** (*Fisher's exact test*) i **test McNemara** (dla tych samych obiektów ocenianych dwukrotnie).

> Danych kategorycznych nie opisuje się średnią ani odchyleniem — tylko liczebnościami i proporcjami (np. na wykresie słupkowym).

Statystyka chi-kwadrat i jej składniki

Statystyka chi-kwadrat (*chi-squared statistic*)

Łączna odległość liczebności obserwowanych od oczekiwanych, czyli takich, jakich należałoby się spodziewać przy prawdziwej H_0 (np. gdyby cechy były niezależne). Każda kategoria lub komórka tabeli dokłada swoją część; im większe różnice, tym większe χ^2.

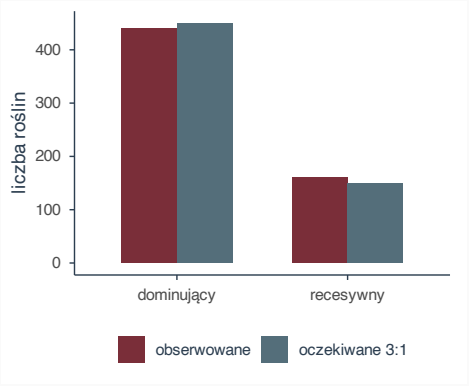
Gdy rośnie…	wartość χ^2…	bo…
różnica obserwowane — oczekiwane	rośnie	silniejsze odstępstwo od H_0
liczebność próby (te same proporcje)	rośnie	większe różnice liczebności

Przeciw H_0 świadczy tylko duże χ^2: im większe χ^2, tym mniejsza wartość p (oblicza ją R).

Chi-kwadrat zgodności: proporcja fenotypów 3:1

- Krzyżówka jednogenowa, pokolenie F2, 600 roślin: 440 o fenotypie dominującym, 160 o recesywnym
- H_0: proporcje fenotypów w populacji wynoszą 3:1; liczebności oczekiwane to szare słupki
- Obserwowane odbiegają od oczekiwanych o 10 roślin w każdej klasie, czyli niewiele: $\chi^2 = 0{,}89$, $p = 0{,}35$

Odchylenie mieści się w granicach przypadku: brak podstaw do odrzucenia proporcji 3:1. Odchylenie zbyt duże, by przypisać je przypadkowi, oznaczałoby odstępstwo od 3:1 (np. letalność, sprzężenie, błąd klasyfikacji).



Chi-kwadrat niezależności: dwie cechy

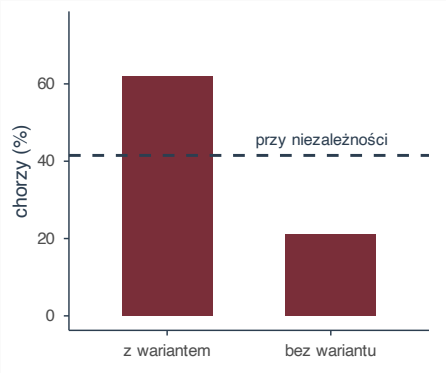
Tabela kontyngencji (*contingency table*)

Zestawienie liczebności obiektów według dwóch cech kategorycznych, z sumami wierszy i kolumn (sumy brzegowe).

	Fenotyp chory	Fenotyp zdrowy	Razem
Genotyp z wariantem	62	38	100
Genotyp bez wariantu	21	79	100
Razem	83	117	200

- H_0: genotyp i fenotyp **niezależne** (proporcje chorych takie same)

Obserwowane i oczekiwane w tabeli 2×2



- Oczekiwane: gdyby genotyp nie miał znaczenia, w obu grupach chorowałoby po 41,5% osób (linia przerywana)
- Obserwowane odsetki: 62% i 21%; każda komórka odbiega od oczekiwanej o 20,5 osoby
- $\chi^2 = 33{,}0$, $p < 0{,}001$ (`chisq.test`): genotyp i fenotyp są powiązane

Warunki testu chi-kwadrat

1. **Obserwacje niezależne**: każdy obiekt liczony raz i w jednej komórce
2. **Liczebności**, nie odsetki ani średnie
3. **Liczebności oczekiwane** (nie obserwowane!) nie za małe: w tabeli 2×2 każda co najmniej 5
4. **Dane sparowane** (ten sam osobnik przed i po): chi-kwadrat niewłaściwy — **test McNemara** (*McNemar's test*), który porównuje liczby zmian w obie strony

> Gdy warunek 3 nie jest spełniony w tabeli 2×2, stosuje się dokładny test Fishera, który oblicza wartość p dokładnie, bez przybliżenia rozkładem chi-kwadrat.

Dokładny test Fishera: kiedy zamiast chi-kwadrat

Reguła dla tabeli 2×2

Jeśli choć jedna liczebność oczekiwana jest mniejsza niż 5, zamiast testu chi-kwadrat stosuje się dokładny test Fishera. Liczą się liczebności oczekiwane, nie obserwowane.

Obserwowane

	poprawa	brak	razem
lek	8	2	10
placebo	1	9	10
razem	9	11	20

Oczekiwane przy niezależności

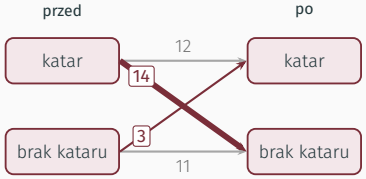
	poprawa	brak	razem
lek	4,5	5,5	10
placebo	4,5	5,5	10
razem	9	11	20

- Poprawa nastąpiła u 9 z 20 osób (45%); przy braku związku po 45% w każdej grupie, czyli 4,5 z 10 $\longrightarrow$ dwie oczekiwane poniżej 5 $\longrightarrow$ test Fishera
- Test Fishera oblicza p dokładnie, bez przybliżenia; w tabeli 2×2 można go stosować zawsze (przy dużych liczebnościach daje wynik zbliżony do chi-kwadrat), ale nadal wymaga niezależności obserwacji

Test McNemara: ten sam pacjent przed i po

Test McNemara (*McNemar's test*)

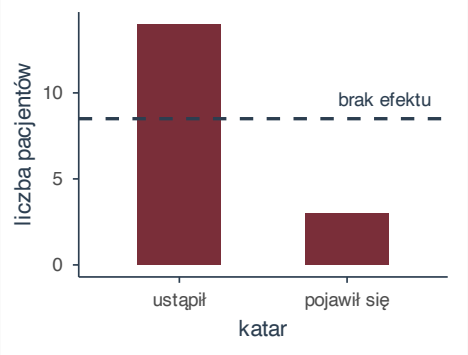
Test dla cechy z dwiema kategoriami (objaw jest lub go nie ma), ocenianej dwukrotnie u tych samych obiektów. Odpowiednik testu sparowanego dla danych kategorycznych.



Doświadczenie: 40 pacjentów z alergią sezonową; katar oceniono przed leczeniem i po 4 tygodniach przyjmowania leku. Grubość strzałki odpowiada liczbie osób.

- Bez zmiany: 23 osoby (12 z katarem przed i po, 11 bez kataru przed i po) — nic nie mówią o działaniu leczenia, test je pomija
- Ze zmianą: 17 osób — katar ustąpił u 14, pojawił się u 3
- Pytanie testu: czy zmiany na lepsze zdarzają się częściej niż zmiany na gorsze?

Test McNemara: zmiany w obie strony



- Liczą się tylko osoby ze zmianą: 17
- H_0: leczenie nie działa, więc zmiany w obie strony są **równie częste** — jak orzeł i reszka: ok. 8,5 na 8,5 (linia przerywana)
- Obserwacja 14 : 3 to przewaga zbyt duża, by przypisać ją przypadkowi: $\chi^2 = 5{,}9$, $p = 0{,}015$ (`mcnemar.test`)

Błąd: tabela „przed/po × katar/brak”, w której każdy pacjent występuje dwa razy (80 wpisów dla 40 osób), analizowana testem chi-kwadrat niezależności.

Dane kategoryczne: przykładowe doświadczenia

Chi-kwadrat zgodności

- Potomstwo krzyżówki dwugenowej: czy fenotypy występują w proporcji 9:3:3:1?
- Czy odsetki grup krwi w badanej grupie odpowiadają odsetkom podawanym dla całej populacji?

Chi-kwadrat niezależności

- Czy odsetek szczepów opornych na antybiotyk różni się między trzema szpitalami?
- Czy ubarwienie ślimaków (jasne, ciemne) wiąże się z typem siedliska (las, łąka)?

Dokładny test Fishera

- Rzadka mutacja: obecna u 4 z 15 chorych i u 0 z 20 zdrowych
- Małe doświadczenie: po leku przeżyło 6 z 8 myszy, po placebo 2 z 8

Test McNemara

- Ci sami pacjenci przed leczeniem i po nim: objaw jest lub go nie ma
- Szybki test i PCR wykonane na tych samych 50 próbkach: czy oba dają wynik dodatni równie często?

3. Testy nieparametryczne

Testy nieparametryczne — zastosowania

Testy parametryczne i nieparametryczne

- Parametryczny (np. test t): zakłada określony rozkład danych, zwykle normalny, i porównuje jego parametry, np. średnie
- Nieparametryczny (*nonparametric*): nie zakłada rozkładu normalnego; zwykle porównuje kolejność obserwacji (rangi), a nie same wartości

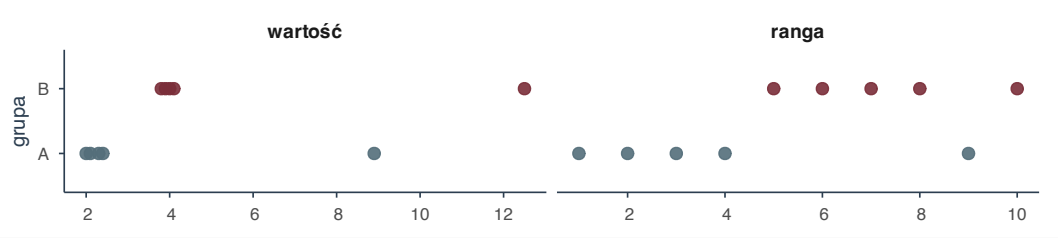
Kiedy stosuje się test nieparametryczny:

- Dane wyraźnie nienormalne (silna skośność, którą widać na histogramie)
- Małe próby, w których normalności nie da się ocenić (moc testu jest wtedy niska)
- Skala porządkowa (stadium, skala nasilenia) — liczy się kolejność, nie odległość
- Silne wartości odstające, które zniekształcają średnią

Ranga i rangowanie

Ranga (*rank*)

Numer miejsca obserwacji po uporządkowaniu wszystkich obserwacji od najmniejszej (ranga 1) do największej.



- Lewy panel: wartości; prawy: rangi tych samych obserwacji, nadane obu grupom razem
- Wartości 8,9 i 12,5 leżą daleko od pozostałych, ale dostają tylko rangi 9 i 10: wielkość odstępu nie wpływa na wynik

Test Manna–Whitneya

Test Manna–Whitneya (*Mann–Whitney U test, Wilcoxon rank-sum*)

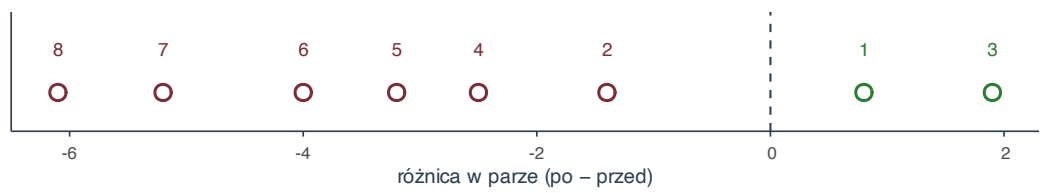
Test rangowy dla dwóch niezależnych grup: sprawdza, czy obserwacje jednej grupy zajmują systematycznie wyższe rangi niż obserwacje drugiej.

- H_0: żadna z grup nie ma systematycznie wyższych wartości
- Dane z poprzedniego slajdu: suma rang grupy A wynosi 19, grupy B 36; gdyby grupy się nie różniły, obie sumy byłyby zbliżone (po ok. 27,5)
- Wynik: $p = 0{,}095$ — przy 5 obserwacjach w grupie to za mało, by odrzucić H_0

Test Wilcoxona dla par

Test Wilcoxona dla par (*Wilcoxon signed-rank test*)

Test rangowy dla par: różnice w parach porządkuje się według wielkości (bez znaku), nadaje im rangi i porównuje rangi różnic dodatnich z rangami różnic ujemnych.



- Liczba nad punktem: ranga wielkości różnicy; bordowe — różnice ujemne, zielone — dodatnie
- Suma rang różnic ujemnych: 32, dodatnich: 4; przy braku efektu obie sumy byłyby zbliżone
- Nieparametryczny odpowiednik testu t sparowanego; nie wymaga normalności różnic

Testy rangowe: przykładowe doświadczenia

- Mann–Whitney (dwie niezależne grupy):
  - masa guza u myszy leczonych i nieleczonych, gdy u kilku myszy guz jest wielokrotnie większy niż u pozostałych
  - nasilenie objawów choroby w skali 0–3 u myszy dwóch szczepów (skala porządkowa)
- Wilcoxon dla par (te same obiekty dwukrotnie):
  - liczba jaj złożonych przez te same samice przed ekspozycją na pestycyd i po niej, gdy różnice są silnie skośne
  - nasilenie bólu w skali 0–10 u tych samych pacjentów przed zabiegiem i po nim

Wspólna cecha

Skala porządkowa, silna skośność albo wartości odstające przy małej próbie. Układ grup (niezależne czy pary) wybiera się tak samo jak dla testu t.

Założenia testów rangowych

- Testy rangowe nie są wolne od założeń: wymagają niezależności obserwacji
- Przy bardzo małych próbach moc jest niska: przy 3 obserwacjach w grupie test w ogóle nie może dać $p < 0{,}05$
- Przy danych normalnych tracą niewiele mocy; przy skośności i wartościach odstających działają lepiej niż test t

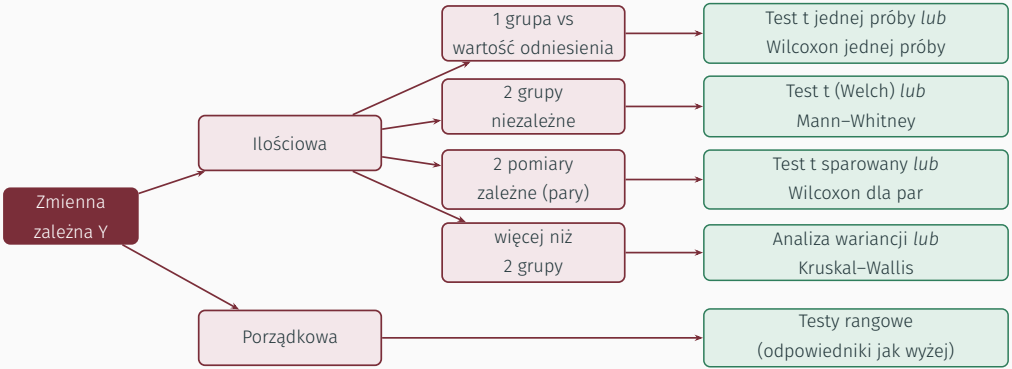
> Test nieparametryczny nie naprawia złego planu: pseudoreplikacja i zależność obserwacji psują go tak samo jak test t.

Odpowiedniki parametryczne i nieparametryczne

Parametryczny	Nieparametryczny (rangi)
Test t jednej próby	Test Wilcoxona dla jednej próby
Test t dwóch prób	Test Manna–Whitneya (Wilcoxona)
Test t sparowany	Test Wilcoxona dla par
Analiza wariancji (więcej niż dwie grupy naraz)	Test Kruskala–Wallisa

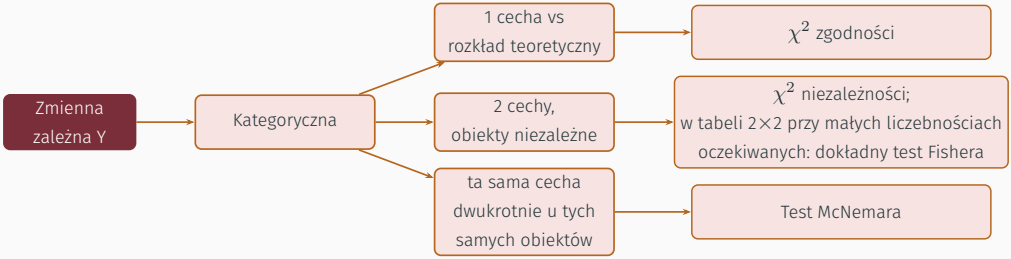
4. Drzewo wyboru testu

Jaki test: zmienna ilościowa lub porządkowa



Pierwsza opcja w zielonym polu: gdy rozkład (oceniany na wykresie) jest zbliżony do normalnego lub próba jest duża, bez silnych wartości odstających; w przeciwnym razie druga opcja (test rangowy).

Jaki test: zmienna kategoryczna



Liczebności oczekiwane to liczebności, jakich należałoby się spodziewać przy prawdziwej H_0; w tabeli 2×2 każda powinna wynosić co najmniej 5.

Ćwiczenie: dobór testu (1/2)

Dla każdej sytuacji wskazać właściwy test:

- Liczba kolonii na 5 płytkach z lekiem i 5 bez leku; na dwóch płytkach kolonii jest kilkakrotnie więcej niż na pozostałych.
- Genotyp (AA, Aa, aa) a status choroby w dużej kohorcie.
- Stężenie białka w tych samych 9 próbkach przed i po obróbce, różnice silnie skośne.

- Działanie niepożądane wystąpiło u 3 z 12 pacjentów leczonych i u 0 z 10 w grupie kontrolnej.

Ćwiczenie: dobór testu (1/2)

Dla każdej sytuacji wskazać właściwy test:

- Liczba kolonii na 5 płytkach z lekiem i 5 bez leku; na dwóch płytkach kolonii jest kilkakrotnie więcej niż na pozostałych. $\longrightarrow$ **Mann–Whitney** (lub transformacja i test t)
- Genotyp (AA, Aa, aa) a status choroby w dużej kohorcie. $\longrightarrow$ **chi-kwadrat** niezależności (tabela 3×2)
- Stężenie białka w tych samych 9 próbkach przed i po obróbce, różnice silnie skośne. $\longrightarrow$ **Wilcoxon dla par**
- Działanie niepożądane wystąpiło u 3 z 12 pacjentów leczonych i u 0 z 10 w grupie kontrolnej. $\longrightarrow$ **test Fishera** (małe liczebności)

Ćwiczenie: dobór testu (2/2)

Dla każdej sytuacji wskazać właściwy test:

- Średnia długość korzeni 30 siewek a wartość podana w opisie odmiany; rozkład zbliżony do normalnego.
- Masa ciała 25 myszy z nokautem genu i 25 myszy typu dzikiego.
- Grubość kory po północnej i po południowej stronie tych samych 20 drzew; różnice zbliżone do normalnego.
- 200 piskląt: czy samce i samice występują w proporcji 1:1?
- Te same 60 roślin oceniono przed opryskiem i po nim: porażona lub zdrowa.
- Stopień uszkodzenia liści w skali 0–4 u dwóch odmian.

Ćwiczenie: dobór testu (2/2)

Dla każdej sytuacji wskazać właściwy test:

- Średnia długość korzeni 30 siewek a wartość podana w opisie odmiany; rozkład zbliżony do normalnego. $\longrightarrow$ **test t jednej próby**
- Masa ciała 25 myszy z nokautem genu i 25 myszy typu dzikiego. $\longrightarrow$ **test t (Welch)**
- Grubość kory po północnej i po południowej stronie tych samych 20 drzew; różnice zbliżone do normalnego. $\longrightarrow$ **test t sparowany**
- 200 piskląt: czy samce i samice występują w proporcji 1:1? $\longrightarrow$ **chi-kwadrat zgodności**
- Te same 60 roślin oceniono przed opryskiem i po nim: porażona lub zdrowa. $\longrightarrow$ **test McNemara**
- Stopień uszkodzenia liści w skali 0–4 u dwóch odmian. $\longrightarrow$ **Mann–Whitney** (skala porządkowa)

5. W praktyce: R

Test t dla par: pomiar przed i po

```r
przed <- c(128, 162, 135, 150, 170, 142)
po    <- c(120, 155, 127, 144, 161, 134)
t.test(po, przed, paired = TRUE)
```

```
    Paired t-test

data:  po and przed
t = -18.183, df = 5, p-value = 9.247e-06
alternative hypothesis: true mean difference is not equal to 0
95 percent confidence interval:
 -8.750519 -6.582814
sample estimates:
mean difference
      -7.666667
```

- **`paired = TRUE`**: i-ta wartość wektora `po` należy do tego samego pacjenta co i-ta wartość wektora `przed`
- Różnice liczone jako `po` — `przed`: średni spadek 7,67 mmHg
- Przedział ufności dla średniej różnicy nie zawiera zera; $p < 0{,}001$

Małe liczebności: test Fishera

```r
# wiersze: lek, placebo; kolumny: poprawa, brak
tab <- matrix(c(8, 1, 2, 9), nrow = 2)
fisher.test(tab)
```

```
    Fisher's Exact Test for Count Data

data:  tab
p-value = 0.005477
alternative hypothesis: true odds ratio is not equal to 1
95 percent confidence interval:
    2.057999 1740.081669
sample estimates:
odds ratio
  27.32632
```

- $p = 0{,}005$ — leczenie i poprawa są powiązane
- Szansa poprawy to stosunek poprawy do jej braku: po leku 8:2, po placebo 1:9
- Iloraz szans z wydruku mówi, ile razy szansa poprawy jest większa po leku: duży, ale bardzo niepewny, 95% CI od 2,1 do 1740, bo liczebności są małe

Podsumowanie

Zestawienie testów z przykładami

Test	Przykład	Funkcja w R
t jednej próby	pH hodowli a wartość 7,4	`t.test(x, mu = …)`
t dwóch prób (Welch)	masa myszy z nokautem i typu dzikiego	`t.test(x, y)`
t sparowany	ciśnienie przed i po leczeniu	`t.test(po, przed, paired = TRUE)`
Mann–Whitney	liczba kolonii z wartościami odstającymi	`wilcox.test(x, y)`
Wilcoxon dla par	białko przed i po obróbce, różnice skośne	`wilcox.test(po, przed, paired = TRUE)`
χ^2 zgodności	fenotypy w F2 a proporcja 3:1	`chisq.test(obs, p = c(0.75, 0.25))`
χ^2 niezależności	genotyp a fenotyp chorobowy	`chisq.test(tabela)`
Fisher	poprawa po leku i placebo, małe liczebności	`fisher.test(tabela)`
McNemar	objaw przed i po leczeniu u tych samych pacjentów	`mcnemar.test(tabela)`

Do zapamiętania

- Test sparowany to test t jednej próby na **różnicach**: szumem jest rozrzut różnic, więc sparowanie usuwa zmienność międzyosobniczą i **zwiększa moc**; wynika z planu, a nie z wyboru analizy po fakcie
- χ^2 mierzy odległość liczebności **obserwowanych** od **oczekiwanych** przy H_0; im większe χ^2, tym mniejsze p
- Tabela 2×2 z małymi liczebnościami oczekiwanymi $\rightarrow$ **Fisher**; te same obiekty dwukrotnie $\rightarrow$ **McNemar** (liczą się tylko obiekty, u których wynik się zmienił)
- Testy **rangowe** działają na kolejności obserwacji: odporne na skośność i wartości odstające, przy danych normalnych tracą niewiele mocy
- **Drzewo wyboru testu** łączy typ danych z metodą

Na następny wykład

Wykład 6: Regresja liniowa

- Od porównywania grup do **zależności ciągłej**: zmiana Y wzdłuż X
- Odczyt nachylenia i wyrazu wolnego
- Wnioskowanie o nachyleniu; przedział ufności i przedział predykcji
- Istotne nachylenie — to jeszcze nie dowód przyczyny

Dziękuję za uwagę

dr inż. Bartosz Czech · bartosz.czech@upwr.edu.pl