

Wykład 1: Wprowadzenie

dr inż. Bartosz Czech

Katedra Genetyki · Uniwersytet Przyrodniczy we Wrocławiu

bartosz.czech@upwr.edu.pl

Plan i cel

- 1 Wprowadzenie do biostatystyki
- 2 Populacje i próby danych
- 3 Testowanie hipotez i estymacja
- 4 Testy statystyczne I: testy t
- 5 Testy statystyczne II: nieparametryczne i kategoriyczne
- 6 Regresja liniowa
- 7 Regresja nieliniowa
- 8 Jakość dopasowania regresji
- 9 Korelacja
- 10 Analiza wariancji (ANOVA)

Zaliczenie

Kurs kończy się **zaliczeniem pisemnym** — sprawdza rozumienie pojęć oraz umiejętność doboru i interpretacji właściwego testu, nie odtwarzanie wzorów z pamięci.

Obecność

- dopuszczalne nieobecności: **do 20%** zajęć — przy 10 wykładach **najwyżej 2**
- przekroczenie limitu rozpatrywane zgodnie z regulaminem studiów
- usprawiedliwienie — niezwłocznie po ustaniu przyczyny

Konsultacje: poniedziałek 14:00–15:30, pokój 306 w Katedrze Genetyki
(proszę o wcześniejszy kontakt mailowy: **bartosz.czech@upwr.edu.pl**)

Podręczniki

- Dobek, Szwackowski — *Statystyka Matematyczna dla Biologów* (podstawowy)
- Whitlock, Schluter — *The Analysis of Biological Data*
- Beckerman, Childs, Petchey — *Getting Started with R*

Darmowe, dostępne online

- Childs i in. — *Introductory Biostatistics with R*
- Holmes, Huber — *Modern Statistics for Modern Biology*
- Navarro — *Learning Statistics with R*
- *OpenIntro Statistics*
- Wickham i in. — *R for Data Science*

- 1 Proces naukowy i hipotezy — od obserwacji do wniosku
- 2 Typy zmiennych i skale pomiarowe
- 3 Jakość pomiaru: dokładność i precyzja
- 4 Pierwszy kontakt z R

Po co statystyka w biologii

Czym jest biostatystyka?

Definicja


Biostatystyka to dział statystyki stosowany do danych z badań biologicznych i medycznych — zestaw metod, którymi planujemy doświadczenie, analizujemy wyniki i wyciągamy z nich wnioski.

- Towarzyszy **całemu badaniu** — od zaplanowania doświadczenia, przez analizę danych, po wniosek
- Potrzebna, bo biologia jest z natury **zmienna**: dwie myszy z miotu różnią się masą, dwie kolonie rosną w różnym tempie, dwa powtórzenia qPCR dają inny wynik
- Pozwala oddzielić **prawdziwy sygnał** — efekt leku, mutacji czy nawozu — od **szumu**, czyli przypadkowej zmienności

Pytanie, na które odpowiada ten przedmiot

Skąd wiemy, że różnica między grupami jest rzeczywista, a nie przypadkowa?

- **Grzegorz Mendel** odkrył prawa dziedziczenia, bo *policzył* tysiące roślin grochu i porównał proporcje z oczekiwaniami
- **Ronald Fisher** stworzył podstawy planowania doświadczeń, analizując wyniki pól doświadczalnych
- Dziś genomika, ekologia i farmakologia opierają swoje wnioski na analizie danych



Ta sama różnica średnich. Wniosek zależy nie od różnicy, lecz od jej wielkości względem rozrzutu.

Opisowa

Podsumowuje to, co faktycznie zmierzaliśmy:
średnie, wykresy, tabele. Nie wychodzi poza próbę.

„Jaka była średnia masa w mojej grupie 20 myszy?”

Wnioskująca

Przenosi wniosek z próby na całą populację —
zawsze z określoną niepewnością.

„Czy wszystkie myszy tego szczepu ważą inaczej po podaniu
leku?”


- **Praca dyplomowa:** „Czy mój związek / nawóz / dieta rzeczywiście działa?” — bez testu to tylko wrażenie
- **Czytanie publikacji:** zapis „ $p = 0,03$, $n = 12$, $\log_2 FC = 1,8$ ” trzeba rozumieć, by ocenić wiarygodność wniosków
- **Planowanie eksperymentu:** „Ile zwierząt, powtórzeń, prób potrzeba, żeby w ogóle coś wykryć?”
- **Krytyczna ocena cudzej pracy:** „Czy autorzy zastosowali właściwy test, czy naciągnęli wynik?”

Zasada przewodnia

Nie uczymy wzorów na pamięć ani liczenia ręcznego. Uczymy się **myśleć o danych**: dobierać właściwy test, rozumieć jego wynik i unikać typowych pułapek.

- Obliczenia wykona za Państwa **R** — na ćwiczeniach
- Na wykładzie budujemy **intuicję**: co liczymy, kiedy i dlaczego oraz jak odczytać wynik z komputera
- Miara sukcesu: patrząc na wynik testu lub wykres, **wiedzą Państwo, co on znaczy** i czy wniosek jest uczciwy

1. Proces naukowy



- **Testowalna** — da się ją sprawdzić danymi
- **Falsyfikowalna** — da się wyobrazić wynik, który by ją obalił
- **Konkretna** — mówi o mierzalnej wielkości, nie o wrażeniu

Słaba

„Ten gen jest ważny dla wzrostu bakterii.” „Ważność” nie jest mierzalną wielkością — nie wiadomo, co z czym porównać.

Dobra

„Odsetek kolonii opornych na ampicylinę jest wyższy u szczepu z plazmidem *bla* niż bez niego.”

HARKing (Hypothesizing After the Results are Known)

Dopasowanie hipotezy do już zobaczonych danych. Przegląda się dziesiątki genów, jeden okazuje się istotny przez przypadek i dopiero wtedy powstaje hipoteza, że to właśnie on był przedmiotem badania.

- Przy wielu porównaniach **coś** zawsze wyjdzie „istotne” przez sam przypadek
- Hipoteza dobrana po fakcie nie jest już testowana — jest tylko opisem szumu
- Dlatego rzetelne badania rejestruje się z góry (*preregistration*)

Dwie hipotezy: zerowa i alternatywna

H_0 — zerowa

- „Nic się nie dzieje”, brak efektu, status quo
- To ją test bierze pod lupę
- Zawsze zawiera równość: *brak różnicy*

H_1 — alternatywna

- „Coś się dzieje”, jest efekt
- To zwykle nasza hipoteza badawcza
- Zawiera różnicę / zależność

Przykład: nokaut genu a masa ciała myszy

H_0 : średnia masa myszy typu dzikiego = średnia masa myszy z nokautem.

H_1 : średnie masy się różnią.

Sąd

- Domniemanie niewinności = punkt wyjścia
- Oskarżyciel musi **udowodnić** winę
- Brak dowodów $\rightarrow$ „niewinny”
- „niewinny” $\neq$ „na pewno nie zrobił”

Test statystyczny

- H_0 (brak efektu) = punkt wyjścia
- Dane muszą **wykazać** efekt
- Słabe dowody $\rightarrow$ „nie odrzucamy H_0 ”
- to nie znaczy „efektu nie ma”

Nie odrzucić $H_0 \neq$ udowodnić H_0 . Brak dowodu efektu to nie dowód braku efektu.

- **Dwustronny** (domyślny): interesuje nas różnica w *dowolną* stronę — masa może wzrosnąć albo spaść
- **Jednostronny**: pytamy tylko o jeden kierunek — np. „czy nawóz zwiększa plon”

Kierunku testu **nie wolno** wybierać po zobaczeniu danych. To ukryta forma naciągania wyniku — test jednostronny łatwiej daje „istotność”. W wątpliwości zostajemy przy dwustronnym.

- **Grupa kontrolna** — punkt odniesienia bez badanego czynnika (np. zwierzęta dostające sam nośnik zamiast leku)
- **Randomizacja** — losowy przydział osobników do grup; wyrównuje ukryte różnice i zmienne zakłócające
- **Ślepa próba** — oceniający wynik nie wie, która grupa jest która; chroni przed nieświadomym naginaniem oceny

Bez grupy kontrolnej nie odróżnimy efektu leku od naturalnego przebiegu choroby. Bez randomizacji „grupa leczona” może przypadkiem składać się z młodszych, zdrowszych osobników.


2. Zmienne i skale pomiarowe

Zmienna — mierzona cecha różniąca się między osobnikami lub obiektami.

Typ zmiennej wyznacza dozwolone metody — najważniejsza decyzja w całej analizie.

Najczęstszy błąd początkującego

Dobór testu do „co chcę udowodnić” zamiast do „jaki typ danych mam”.



Typ	Cecha biologiczna	Co można policzyć
Ciągła	Masa guza, stężenie białka, pH, długość korzenia	Średnia, SD, test t
Dyskretna	Liczba kolonii, liczba jaj, liczba mutacji	Zliczenia
Nominalna	Genotyp (WT/mutant), płeć, przeżył/zginął	Proporcje, chi-kwadrat
Porządkowa	Stadium (I–IV), skala nasilenia objawów	Mediana, testy rangowe

Porządkowa ma kolejność, ale odstępstwa nie są równe: różnica między stadium I a II nie musi być „taka sama” jak między III a IV.

Interwałowa (przedziałowa)

Równe odstępstwa, ale **zero jest umowne**. Nie wolno mówić „dwa razy więcej”.

Temperatura w °C: 20° nie jest „dwa razy cieplejsze” niż 10°.

Ilorazowa

Zero jest **bezwzględne** — oznacza całkowity brak wielkości (0 mg = brak masy). Dlatego stosunki mają sens.

Masa, stężenie, długość: 10 mg to naprawdę dwa razy więcej niż 5 mg.

Większość pomiarów biologicznych jest ilorazowa.

To, że coś jest zapisane cyfrą, nie znaczy, że wolno liczyć z tego średnią.

- Numer klatki, numer próbki, kod pacjenta — to etykiety, nie wielkości; średnia nie ma sensu
- Skala bólu 1–10 — porządkowa; różnica „3→4” nie równa się „7→8”
- Genotyp 0 / 1 / 2 (liczba alleli) — **porządkowa/addytywna**: cyfry mają naturalną kolejność, a „średnia dawka alleli” akurat bywa sensowna

Test kontrolny

„Czy średnia z tych liczb ma sens biologiczny?” Jeśli nie — to nie jest zmienna ilościowa.

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	
Liczba młodych w miocie	
Grupa krwi (A, B, AB, 0)	
Stopień złośliwości (G1–G4)	
Genotyp 0 / 1 / 2 (liczba alleli)	

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	ilościowa ciągła
Liczba młodych w miocie	
Grupa krwi (A, B, AB, 0)	
Stopień złośliwości (G1–G4)	
Genotyp 0 / 1 / 2 (liczba alleli)	

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	ilościowa ciągła
Liczba młodych w miocie	ilościowa dyskretna
Grupa krwi (A, B, AB, 0)	
Stopień złośliwości (G1–G4)	
Genotyp 0 / 1 / 2 (liczba alleli)	

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	ilościowa ciągła
Liczba młodych w miocie	ilościowa dyskretna
Grupa krwi (A, B, AB, 0)	nominalna
Stopień złośliwości (G1–G4)	
Genotyp 0 / 1 / 2 (liczba alleli)	

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	ilościowa ciągła
Liczba młodych w miocie	ilościowa dyskretna
Grupa krwi (A, B, AB, 0)	nominalna
Stopień złośliwości (G1–G4)	porządkowa
Genotyp 0 / 1 / 2 (liczba alleli)	

Cecha	Typ
Stężenie glukozy we krwi [mg/dl]	ilościowa ciągła
Liczba młodych w miocie	ilościowa dyskretna
Grupa krwi (A, B, AB, 0)	nominalna
Stopień złośliwości (G1–G4)	porządkowa
Genotyp 0 / 1 / 2 (liczba alleli)	porządkowa / addytywna

Niezależna (X) — objaśniająca

To, co zmieniamy lub według czego dzielimy grupy:
dawka, genotyp, traktowanie, temperatura.

Zależna (Y) — objaśniana

Odpowiedź, którą mierzymy: masa, ekspresja,
przeżycie, plon.

Pytanie badawcze prawie zawsze brzmi: „Czy X wpływa na Y?”

Dawka leku (X) → wielkość guza (Y). Genotyp (X) → tempo wzrostu (Y).

Zmienna zakłócająca (confounder)

Trzeci czynnik, powiązany **jednocześnie** z X i z Y, który zniekształca obraz zależności.



Jeśli myszy jednego genotypu były przypadkiem starsze, „efekt genotypu” na masę może być w rzeczywistości efektem wieku.




3. Jakość pomiaru

Dokładność a precyzja

Dokładność — jak blisko prawdziwej wartości.

Precyzja — jak blisko siebie są kolejne pomiary.

To dwie **różne** rzeczy. Pomiar może być precyzyjny, a mimo to systematycznie zły.



Sytuacja	Problem	Objaw
Pipeta źle skalibrowana (95 zamiast 100 μl)	niedokładność	wyniki systematycznie zaniżone
Pipeta zużyta, tłok „skacze”	brak precyzji	duży rozrzut powtórzeń
Spektrofotometr bez próby zerowej	niedokładność	stałe przesunięcie odczytów
Drżąca ręka przy odczycie menisku	brak precyzji	losowe wahania odczytu

Systematyczny (bias)

- Przesuwa wyniki zawsze w tę samą stronę
- Psuje **dokładność**
- **Nie znika** przy uśrednianiu powtórzeń

Losowy (random)

- Rozrzuca wyniki w obie strony
- Psuje **precyzję**
- **Uśrednia się** — więcej powtórzeń go redukuje

Reguła praktyczna

Powtarzanie pomiaru redukuje błąd losowy, ale NIE naprawia błędu systematycznego. Ten trzeba usunąć u źródła — kalibracja, blank, kontrole. Sto pomiarów źle skalibrowaną pipetą to sto zaniżonych wyników.

- Każda liczba w biologii ma **jednostkę** — bez niej „stężenie 5” nic nie znaczy
- Liczba **cyfr znaczących** mówi, jak precyzyjny był pomiar — zapis „12,7384 g” obiecuje dokładność do dziesiątych części miligrama, której zwykła waga laboratoryjna nie ma
- Nie raportuj więcej cyfr, niż naprawdę daje metoda pomiaru

4. Pierwszy kontakt z R

Dane w R: ramka danych

Obserwacje = **wiersze**, zmienne = **kolumny**; taka tabela to **ramka danych** (ang. *data frame*).

```
myszy <- data.frame(  
  genotyp = c("WT", "WT", "WT", "KO", "KO", "KO"),  
  masa_g  = c(22.1, 23.4, 21.8, 25.6, 26.9, 24.8)  
)  
str(myszy)
```

'data.frame': 6 obs. of 2 variables:

\$ genotyp: chr "WT" "WT" "WT" "KO" ...

\$ masa_g : num 22.1 23.4 21.8 25.6 26.9 24.8

Jak to czytać

str() pokazuje typ każdej kolumny: **chr** to tekst (zmienna nominalna — tu genotyp), **num** to liczby (zmienna ilościowa — tu masa). Jeden wiersz = jedna mysz.

```
head(myszy, 3)
summary(myszy$masa_g)
```

```
   genotyp masa_g
1      WT    22.1
2      WT    23.4
3      WT    21.8
```

```
   Min. 1st Qu. Median  Mean 3rd Qu.  Max.
21.80  22.43  24.10 24.10  25.40 26.90
```

Jak to czytać

`head()` pokazuje kilka pierwszych wierszy. `summary()` daje pięć liczb opisujących rozrzut: minimum, dolny kwartył, medianę, górny kwartył i maksimum — plus średnią. Tu mediana i średnia są równe (24,1), co nie wskazuje na wyraźną skośność rozkładu.

Średnia i odchylenie standardowe

```
mean(myszy$masa_g)
sd(myszy$masa_g)
tapply(myszy$masa_g, myszy$genotyp, mean)
```

```
[1] 24.1
```

```
[1] 2.01792
```

KO	WT
25.767	22.433

Jak to czytać

`mean()` i `sd()` liczą średnią i odchylenie standardowe wektora liczb. `tapply()` liczy to samo **osobno w grupach**: średnia masa KO to około 25,8 g, WT — około 22,4 g.

Sygnał czy szum?

Grupy różnią się średnią o ponad 3 g. Czy to efekt nokautu, czy przypadek? Na to odpowiada dopiero test statystyczny — w dalszej części kursu.

Wykres jednym poleceniem


```
boxplot(masa_g ~ genotyp, data = myszy,  
        ylab = "masa (g)", col = "grey85")
```

Zapis $y \sim x$

„masa w zależności od genotypu”. Ten sam zapis wróci przy testach i regresji.

Jak czytać pudełko

Linia w środku to mediana, brzegi pudełka to kwartyle (rozstęp międzykwartylowy), wąsy sięgają skrajnych typowych wartości.



- `<-` przypisuje wynik do nazwy; `$` wyciąga kolumnę z ramki
- Funkcję wywołujemy jako `nazwa(argumenty)` — np. `mean(x)`
- `data = myszy` mówi funkcji, gdzie szukać kolumn
- Formuła `y ~ x` czyta się „y w zależności od x”

Reguła praktyczna

Dane trzymamy w formacie długim: jedna kolumna to jedna zmienna, jeden wiersz to jedna obserwacja. W tej postaci wszystkie funkcje testowe działają bez przeróbek.

Podsumowanie

- Biologia jest zmienna — zadaniem statystyki jest oddzielić **sygnał** od **szumu**
- **Hipotezę formułujemy przed danymi**, nie po zobaczeniu wyniku
- **Typ zmiennej** (ciągła / dyskretna / nominalna / porządkowa) rządzi wyborem testu; liczba $\neq$ zmienna ilościowa
- Dokładność $\neq$ precyzja — **błąd systematyczny się nie uśrednia**, trzeba go usunąć u źródła

Wykład 2: Populacje i próby danych

Nauczymy się **opisywać zmienność liczbami**: średnia i mediana, odchylenie standardowe, rozkład normalny oraz kluczowe rozróżnienie SD kontra SE.

Dziękuję za uwagę

dr inż. Bartosz Czech · bartosz.czech@upwr.edu.pl